

투빅스 12기 정규과정

ToBig's 11기 이영전

Logistic Regression & Classification

Unit 01 | Machine Learning

Unit 02 | Logistic Regression I, II

Unit 03 | MLE(Maximum Likelihood Estimation)

Unit 04 | Optimizer

Unit 05 | Tutorial & Assignment

Unit 01 | Machine Learning

◆ Basic concept of ML

- What is ML?
- What is learning?
 - Supervised?
 - Unsupervised?
- What is regression?
- What is classification?

Unit 01 | Machine Learning

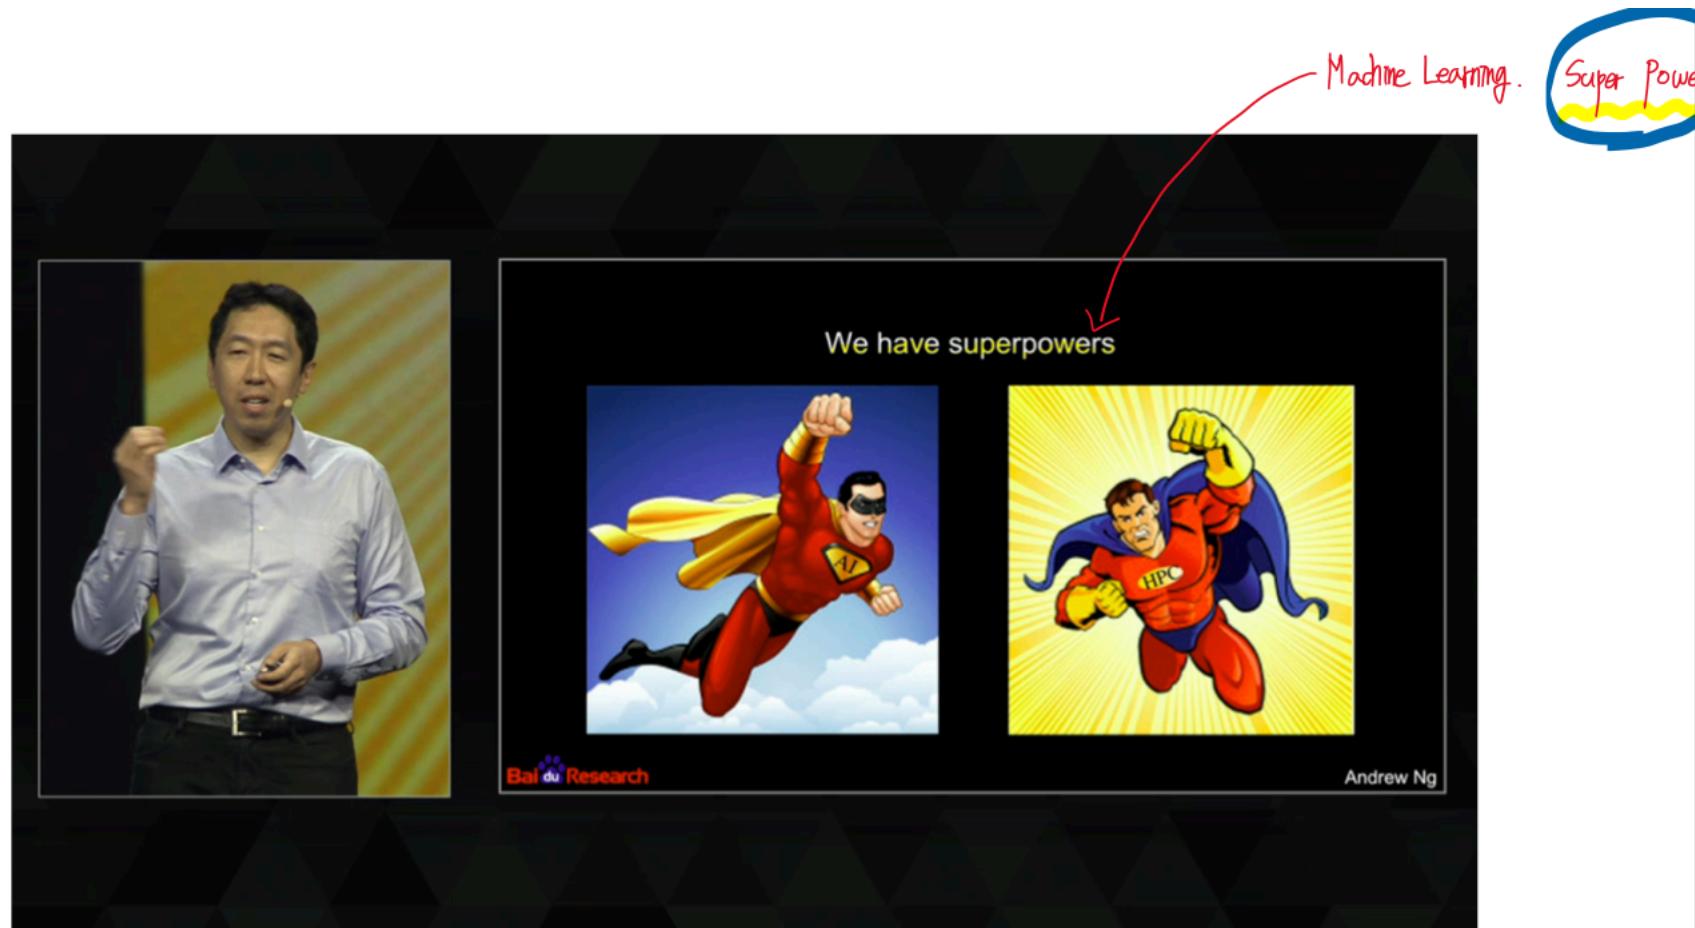
◆ About ML

세기의 대국. 2016年 3月 → 역사적인 순간...



Unit 01 | Machine Learning

◆ About ML



Unit 01 | Machine Learning

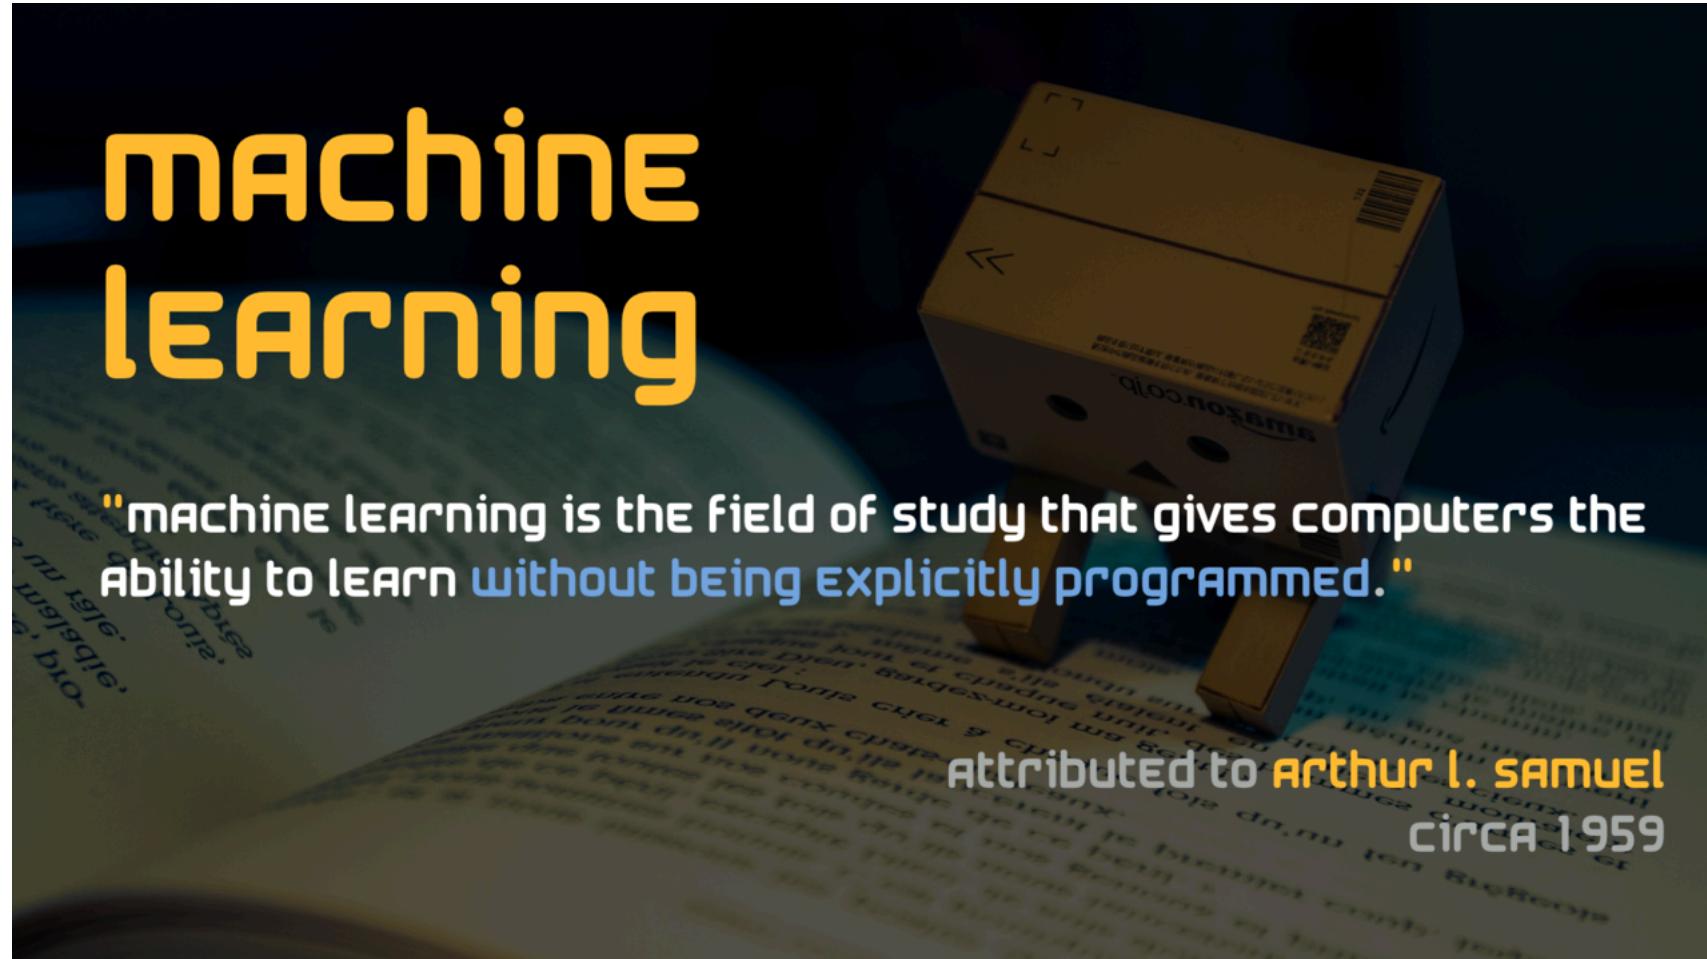
◆ About ML

Machine Learning

- Limitations of explicit programming ← 손코딩의 한계
(Logic Coding)
 - Spam filter: many rules
 - Automatic driving: too many rules

Unit 01 | Machine Learning

◆ About ML



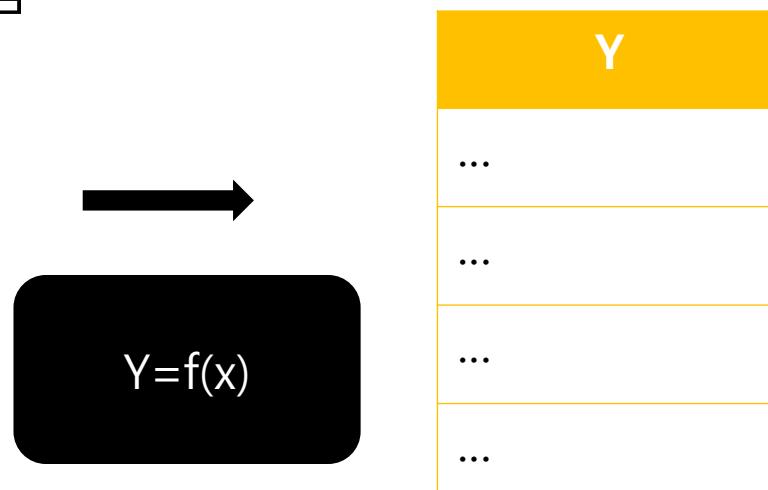
Unit 01 | Machine Learning

◆ 머신러닝의 종류 – Label의 유무에 따른 구분

- 1. Supervised Learning

- ✓ **learning with labeled examples** – training set
- ✓ **Label이 존재하는 데이터**를 이용해 독립변수 X와 종속변수 Y사이의 관계를 찾아 Test 데이터의 Y를 예측하기 위한 학습
- ✓ 분류, 회귀 모델이 Supervised Learning에 해당됨

	X_1	X_2	...	X_d
Data_1
Data_2
...
Data_n



Unit 01 | Machine Learning

◆ 머신러닝의 종류 – Label의 유무에 따른 구분

- 2. Unsupervised Learning

- ✓ **Un-labeled data**
- ✓ **Label이 존재하지 않는 데이터**를 이용해 데이터에 내재된 특징을 분석하기 위한 학습
- ✓ 군집화, 연관규칙분석이 비지도학습에 해당됨

	X_1	X_2	...	X_d
Data_1
Data_2
...
Data_n

Unit 01 | Machine Learning

◆ 머신러닝의 종류 – 학습목적에 따른 구분

* Types of supervised learning

크게 세 가지의 방법이 존재한다.

- ① • Predicting final exam score based on time spent
 - regression
- ② • Pass/non-pass based on time spent
 - binary classification // 2가지 문제 분류.
- ③ • Letter grade (A, B, C, E and F) based on time spent
 - multi-label classification

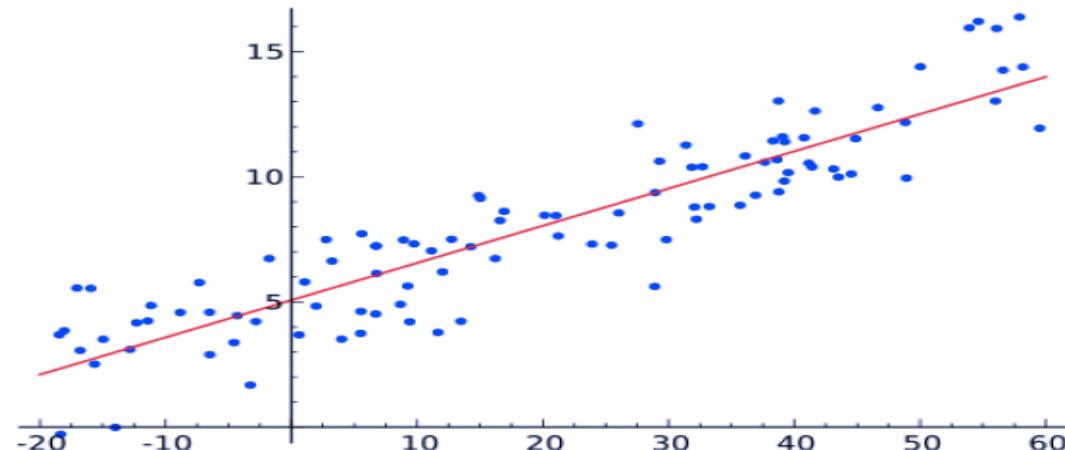
Unit 01 | Machine Learning

◆ 머신러닝의 종류 – 학습목적에 따른 구분

- 1. Regression

- ✓ 연속형(Continuous) 변수를 예측하는 방법론
- ✓ 다중선형회귀분석, 인공신경망, SVR(Support Vector Regression) 등

Multiple Linear Regression

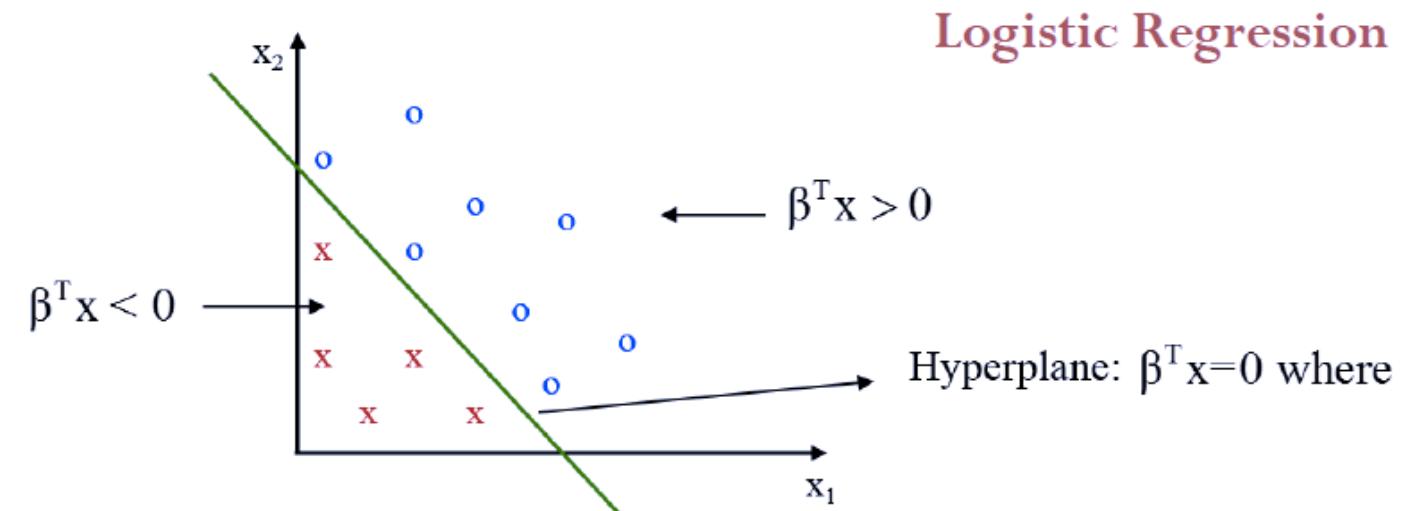


Unit 01 | Machine Learning

◆ 머신러닝의 종류 – 학습목적에 따른 구분

• 2. Classification

- ✓ 명목형(Categorical) 변수를 예측하는 방법론
- ✓ Logistic Regression, Naïve Bayes, Decision Tree, SVM 등



Classifier

$$y = \frac{1}{(1 + \exp(-\beta^T x))}$$

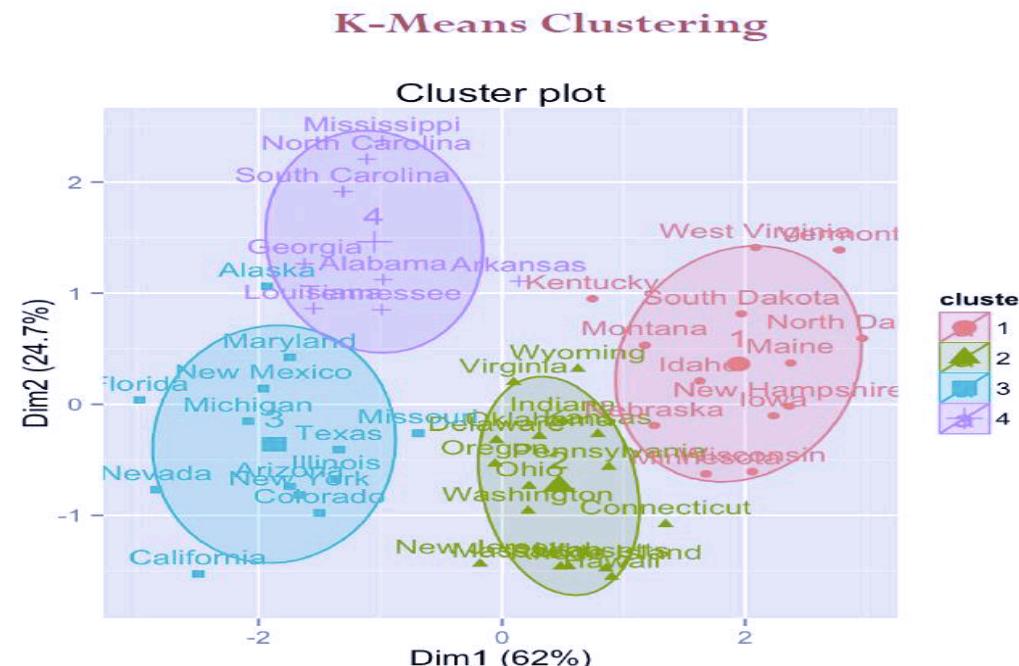
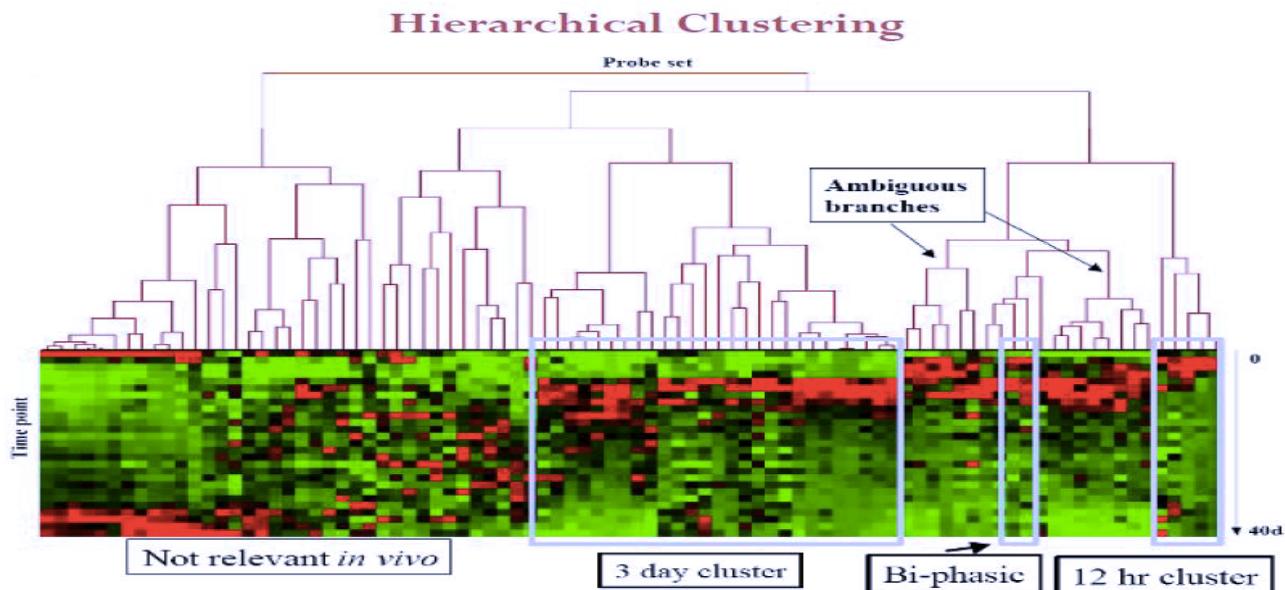
$y \rightarrow 1$	if	$\beta^T x \rightarrow \infty$
$y = \frac{1}{2}$	if	$\beta^T x = 0$
$y \rightarrow 0$	if	$\beta^T x \rightarrow -\infty$

Unit 01 | Machine Learning

◆ 머신러닝의 종류 – 학습목적에 따른 구분

- 3. Clustering

- ✓ 유사한 개체들의 집단을 판별하는 방법론
- ✓ Hierarchical Clustering, K-Means Clustering 등



Unit 01 | Machine Learning

◆ 머신러닝 학습 목표

- 우리가 회귀 분석을 배우는 이유

오늘 배우는 Logistic Regression 어디에 쓰이나요?

왜 배우죠?



Unit 01 | Machine Learning

◆ 머신러닝 학습 목표

Goals

- Basic understanding of machine learning algorithms
 - ✖ - Linear regression, Logistic regression (classification)
- Neural networks, Convolutional Neural Network, Recurrent Neural Network
 - Solve your problems using machine learning tools
- Tensorflow and Python
- Deep Learning을 이해하기 위한 초석.

Unit 01 | Machine Learning

◆ 머신러닝 학습 목표

Goals

Machine Learning의 기본을 잘 다져놓으면
Deep Learning을 학습 할 때 큰 도움이 된다!

- Basic understanding of machine learning algorithms

- Solve your problems using machine learning tools

- Tensorflow and Python

Unit 01 | Machine Learning

Unit 02 | Logistic Regression I, II

Unit 03 | MLE(Maximum Likelihood Estimation)

Unit 04 | Optimizer

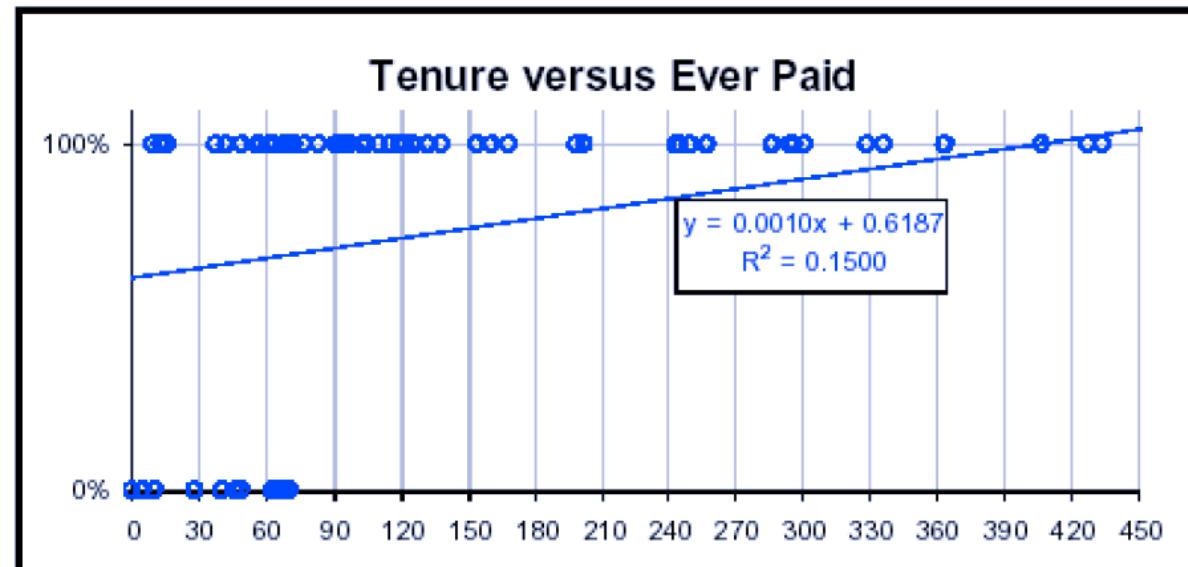
Unit 05 | Tutorial & Assignment

Unit 02 | Logistic Regression

◆ Logistic Regression

- Logistic Regression의 목적
 - ✓ Binary한 종속변수에 대하여 회귀식의 형태로 모형을 추정함
 - ✓ Machine Learning의 종류 중 Supervised Learning, Classification에 속함

$$P(Y = 1) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$



Unit 02 | Logistic Regression

◆ Logistic Regression



를 추정함
왜 배우는지

ion은 회귀 계수에 대한 비선형 함수
해가 존재하지 않음

다. 어떻게 사용하는지

어떻게 응용할 수 있는지

질문의 꼬리를 물며 배워보자!

$$\ln L(X, y, \beta) = \sum_{i=1}^R y_i \ln(\sigma(x_i, \beta)) + (1 - y_i) \ln(1 - \sigma(x_i, \beta))$$

Unit 02 | Logistic Regression

◆ Logistic Regression I

- 로지스틱 회귀모델 배경
- 로지스틱 회귀모델 형태
- Odds

◆ Logistic Regression II

- 파라미터 추정
- 로지스틱 회귀모델 결과 및 해석
- 로지스틱 회귀모델 예제

Unit 02 | Logistic Regression

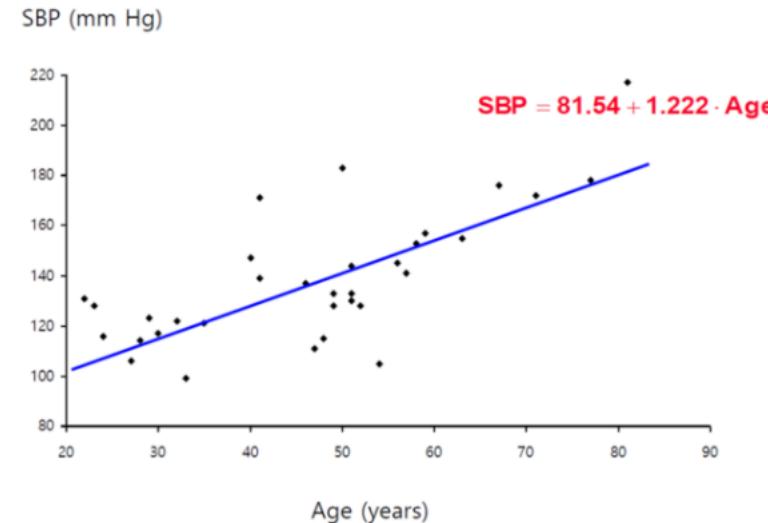
◆ Logistic Regression I

• 0. 문제의식

✓ 다중선형회귀(Multiple Linear Regression)

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

Age	SBP	Age	SBP	Age	SBP
22	131	41	139	52	128
23	128	41	171	54	105
24	116	46	137	56	145
27	106	47	111	57	141
28	114	48	115	58	153
29	123	49	133	59	157
30	117	49	128	63	155
32	122	50	183	67	176
33	99	51	130	71	172
35	121	51	133	77	178
40	147	51	144	81	217

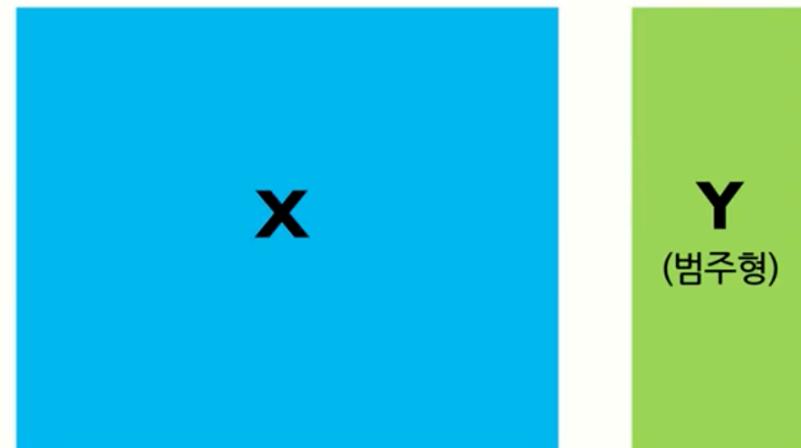


Unit 02 | Logistic Regression

◆ Logistic Regression I

• 0. 문제의식

- ✓ 로지스틱 회귀모델 필요성



- 범주형 반응변수
 - 이진변수 (반응변수 값 $\in 0 \text{ or } 1$)
 - 멀티변수 (반응변수 값 $\in 1 \text{ or } 2 \text{ or } 3\text{이상}$)
- 선형회귀모델과는 다른 방식으로 접근해야 될 필요성

Unit 02 | Logistic Regression

◆ Logistic Regression I

• 0. 문제의식

✓ 응용예제

- 새로운 관측치가 왔을 때 이를 기존 범주 중 하나로 예측(범주예측)

✓ 로지스틱 회귀모델의 사용

- 제품이 불량인지 양품인지 분류
- 고객이 이탈고객인지 잔류고객인지 분류
- 카드 거래가 정상인지 사기인지 분류
- 내원 고객이 질병이 있는지 없는지 분류
- ...

Unit 02 | Logistic Regression

◆ Logistic Regression I

- 로지스틱 회귀모델 이론 배경

✓ 어떤 이론적 배경을 가지고 출발했을까?

$$\underline{Y_i} = \beta_0 + \beta_1 X_i + \varepsilon_i \quad Y_i = 0 \text{ or } 1$$

Assume $\underline{E(\varepsilon_i)} = 0$ / $\underline{E(Y_i)} = \beta_0 + \beta_1 X_i$

Consider Y_i to be a Bernoulli random variable

$$P(Y_i = 1) = \pi_i$$

$$P(Y_i = 0) = 1 - \pi_i$$

$$E(\underline{Y_i}) = \underline{1} \cdot \underline{\pi_i} + \underline{0} \cdot \underline{(1 - \pi_i)} = \circled{\pi_i}$$

$$E(Y_i) = \beta_0 + \beta_1 X_i = \pi_i$$

X값이 주어졌을 때 출력변수 Y가 1의 값을 가질 확률

Unit 02 | Logistic Regression

◆ Logistic Regression

- ✓ 로지스틱 회귀모델 이론 배경

X 값이 주어졌을 때, Y가 특정 범주 값을 가질 확률
값으로 표현되는 모델이다.

Consider Y_i to be a Bernoulli random variable

$$P(Y_i = 1) = \pi_i$$

$$P(Y_i = 0) = 1 - \pi_i$$

그럼, 과연 이렇게 직선으로 표현하는 게 맞는 걸까?

$$E(Y_i) = 1 \cdot \pi_i + 0 \cdot (1 - \pi_i) = \pi_i$$

$$E(Y_i) = \beta_0 + \beta_1 X_i = \pi_i$$

X값이 주어졌을 때 출력변수 Y가 1의 값을 가질 확률

Unit 02 | Logistic Regression

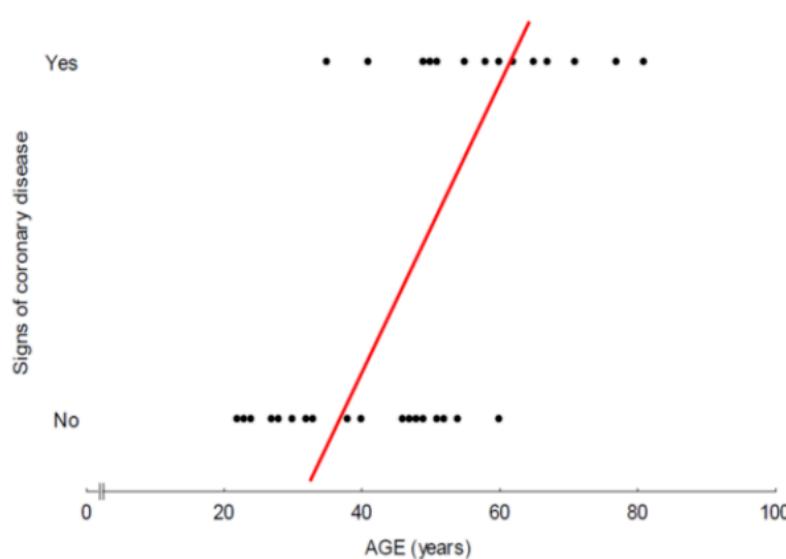
◆ Logistic Regression I

- 로지스틱 회귀모델

- ✓ 출력변수가 연속형이 아닌 이진 범주형 질병유무?
- ✓ 두 변수 사이의 관계식은 선형인가?

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

Age	CD	Age	CD	Age	CD
22	0	40	0	54	0
23	0	41	1	55	1
24	0	46	0	58	1
27	0	47	0	60	1
28	0	48	0	60	0
30	0	49	1	62	1
30	0	49	0	65	1
32	0	50	1	67	1
33	0	51	0	71	1
35	1	51	1	77	1
38	0	52	0	81	1

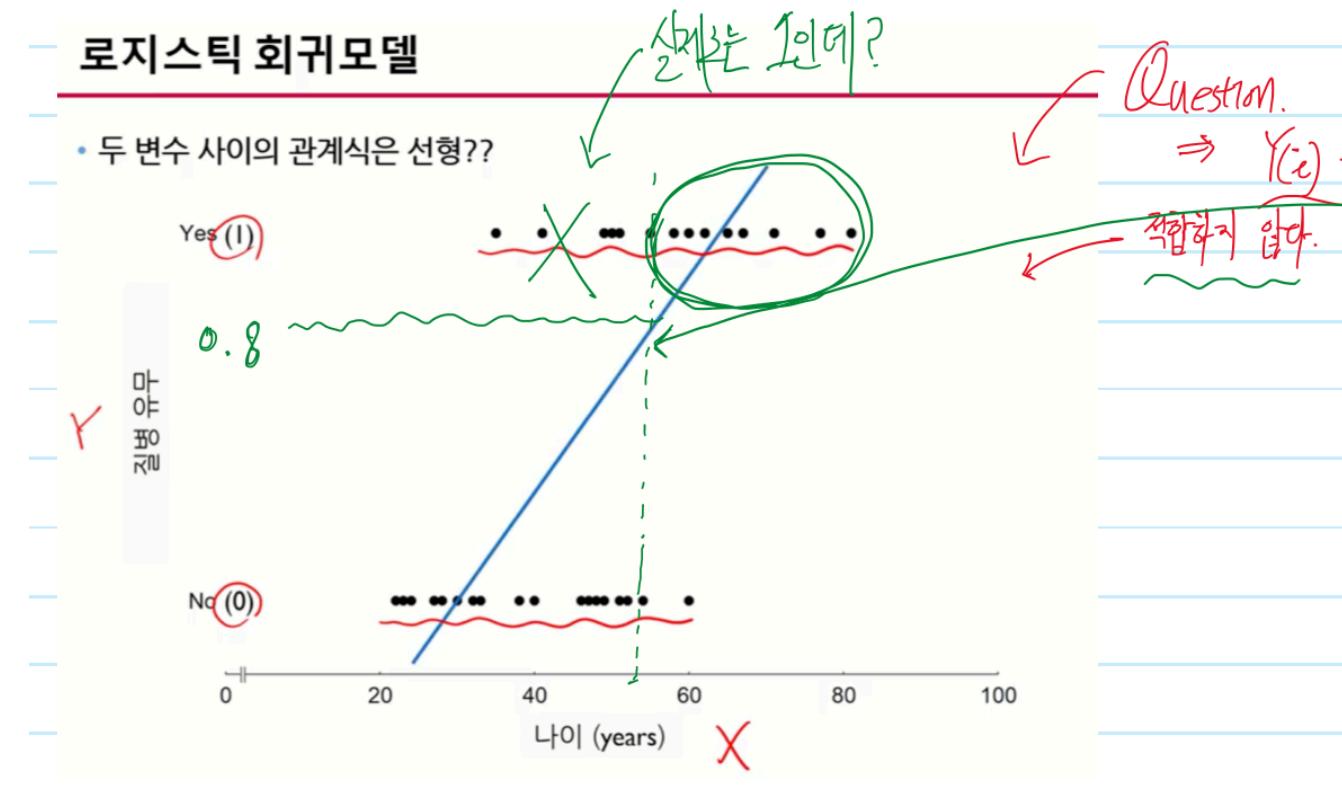


Unit 02 | Logistic Regression

◆ Logistic Regression I

- 로지스틱 회귀모델

- ✓ 두 변수 사이의 관계식을 직선으로 표현하는 게 맞을까?



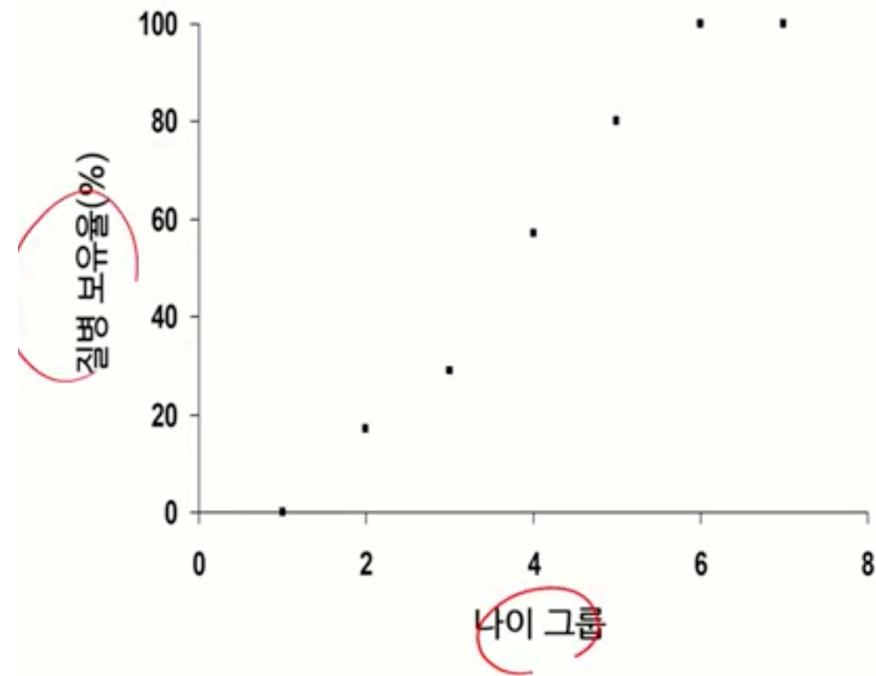
Unit 02 | Logistic Regression

◆ Logistic Regression I

- 로지스틱 회귀모델

- ✓ 확률변수 – 나이그룹
- ✓ 각 나이 대별로 질병에 걸릴 확률

나이 그룹	그룹내 수	질병	
		질병보유자 수	%
20 - 29	5	0	0
30 - 39	6	1	17
40 - 49	7	2	29
50 - 59	7	4	57
60 - 69	5	4	80
70 - 79	2	2	100
80 - 89	1	1	100



Unit 02 | Logistic Regression

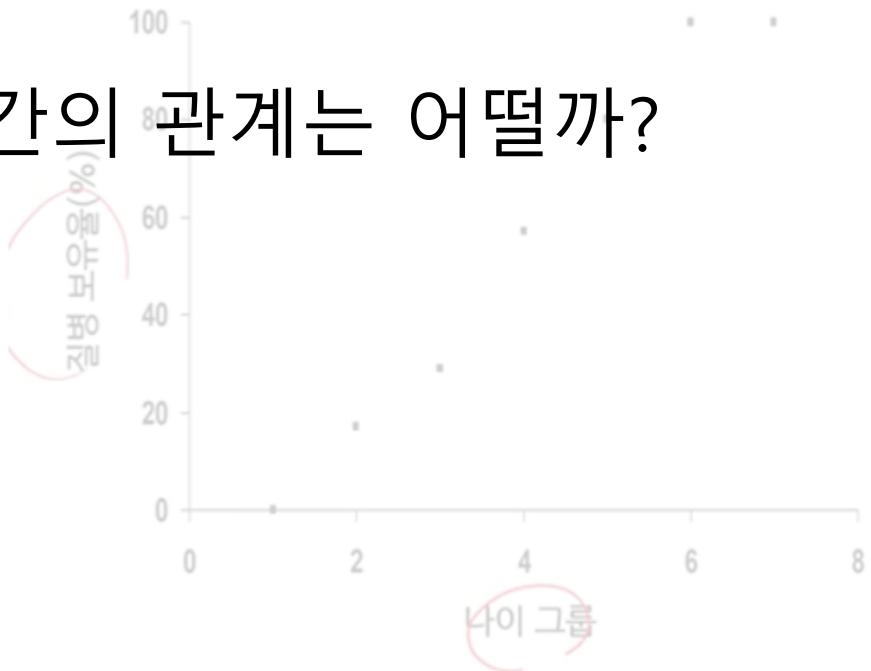
◆ Logistic Regression |

- 로지스틱 회귀모델

- ✓ 확률변수 – 나이그룹
- ✓ 각 나이 대별로 질병에 걸릴 확률

나이 그룹	그룹내 수	질병	
		질병보유자 수	%
30 - 39	6	1	17
40 - 49	7	2	29
50 - 59	7	4	57
60 - 69	5	4	80
70 - 79	2	2	100
80 - 89	1	1	100

Q. 나이 그룹과 질병 보유율 간의 관계는 어떨까?

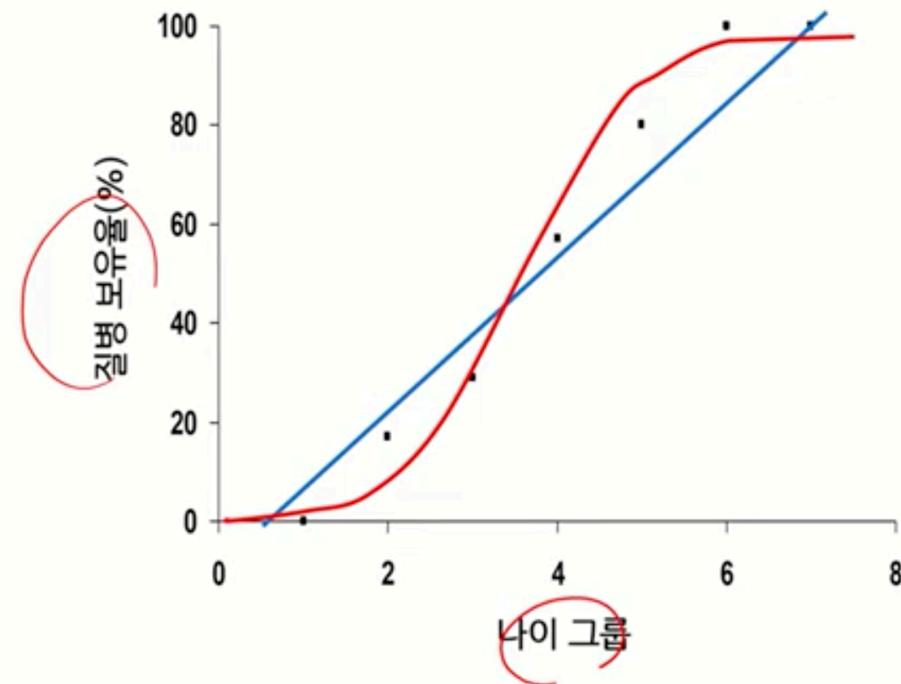
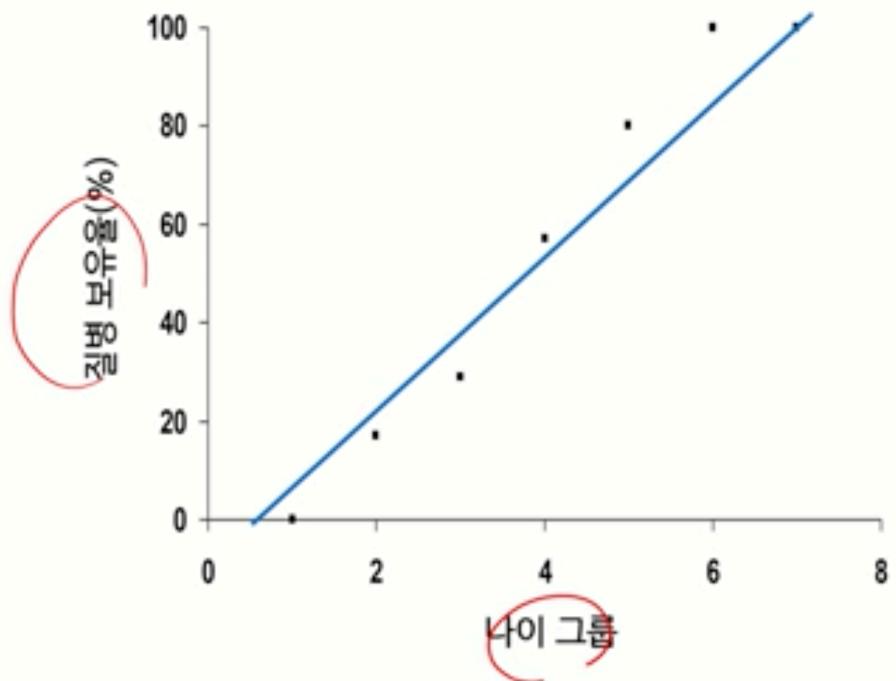


Unit 02 | Logistic Regression

◆ Logistic Regression I

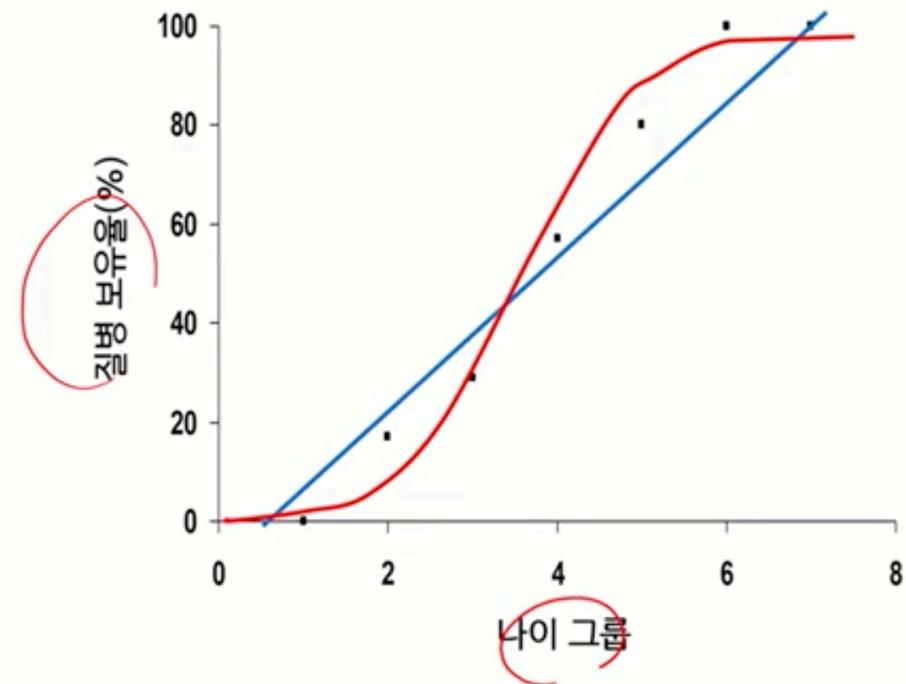
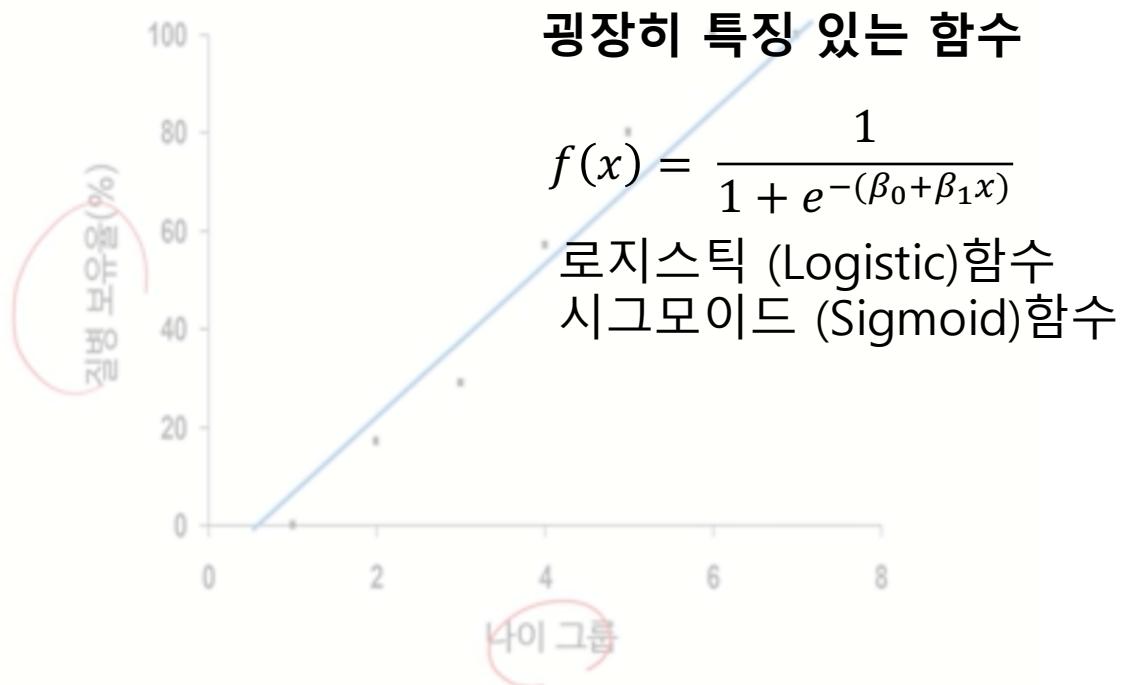
- 로지스틱 회귀모델

- ✓ 선형으로 표현
- ✓ S-Curve로 표현



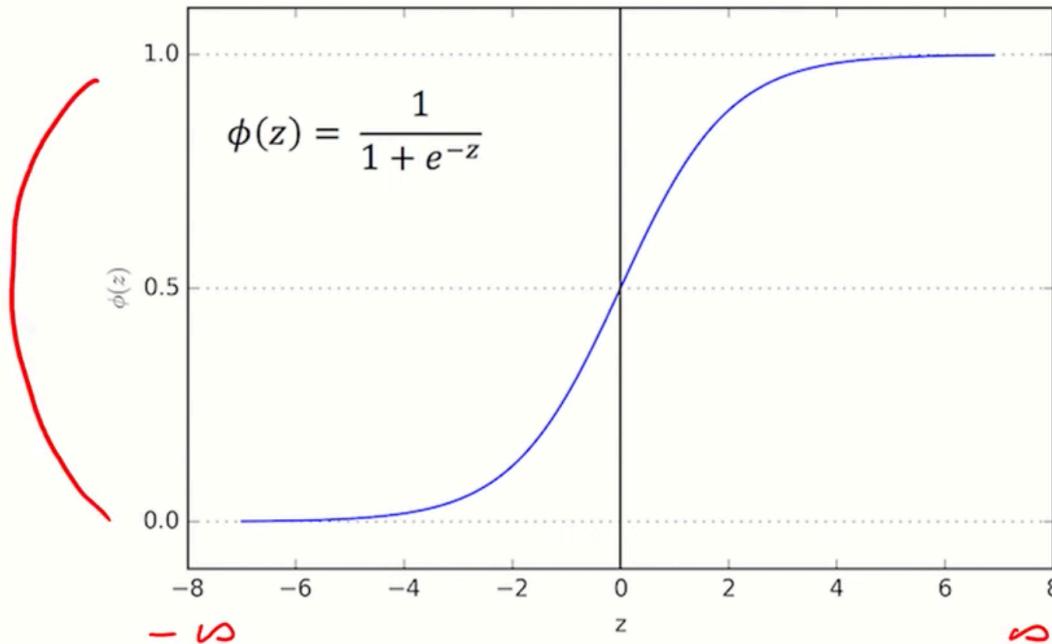
Unit 02 | Logistic Regression

◆ Logistic Regression



◆ Logistic Regression I

- 로지스틱 함수



- Logistic function, Sigmoid function, Squashing function (Large input → Small output)
- 아웃풋 범위: 0~1
- 인풋값에 대해 단조증가 (혹은 단조감소) 함수
- 미분결과를 아웃풋의 함수로 표현 가능 (Gradient learning method에 유용하게 사용)

$$\frac{d\phi(z)}{dz} = \frac{1}{1+e^{-z}} \left(1 - \frac{1}{1+e^{-z}}\right) = \phi(z)(1 - \phi(z))$$

◆ Logistic Regression I

- 로지스틱 함수



$$E(y) = \pi(\underline{X = x}) = P(Y = 1|X = x) = 1 - P(Y = 0|X = x)$$

단순로지스틱 회귀모델: 입력변수 X 가 1개인 로지스틱 회귀모델

$$E(y) = \pi(X = x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

관측치 x 가 범주 1에 속할 확률

(Probability that an observation x belongs to class 1)

◆ Logistic Regression I

- 로지스틱 함수 β_1 해석

$$E(y) = \pi(X = x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

β_1 의 해석 → 직관적이지 못함

- 승산 (Odds)
 - 성공 확률을 p 로 정의할 때, 실패 대비 성공 확률 비율

$$Odd = \frac{p}{1 - p}$$

$$p = 1 \rightarrow odd = \infty$$

$$p = 0 \rightarrow odd = 0$$

◆ Logistic Regression I

- 로지스틱 함수 β_1 해석



2018 FIFA WORLD CUP
June 14th - July 15th, 2018
Various Locations throughout Russia

ODDS TO WIN: 7/14/2014	OPENING	CURRENT	ODDS TO WIN:	OPENING	CURRENT
	ODDS	ODDS		7/14/2014	ODDS
96101 GERMANY	5/1	4/1	96117 SWEDEN	80/1	100/1
96102 BRAZIL	8/1	5/1	96118 SERBIA	100/1	150/1
96103 FRANCE	10/1	11/2	96119 SENEGAL	500/1	150/1
96104 SPAIN	8/1	13/2	96120 EGYPT	500/1	200/1
96105 ARGENTINA	8/1	7/1	96121 ICELAND	1000/1	200/1
96106 BELGIUM	15/1	10/1	96122 PERU	500/1	200/1
96107 ENGLAND	25/1	15/1	96123 NIGERIA	150/1	200/1
96108 PORTUGAL	30/1	20/1	96124 JAPAN	150/1	300/1
96109 URUGUAY	50/1	30/1	96125 COSTA RICA	200/1	250/1
96110 COLOMBIA	20/1	40/1	96126 AUSTRALIA	300/1	300/1
96111 RUSSIA	20/1	40/1	96127 MOROCCO	500/1	500/1
96112 CROATIA	60/1	40/1	96128 IRAN	2000/1	500/1
96113 POLAND	100/1	40/1	96129 SOUTH KOREA	200/1	500/1
96114 MEXICO	50/1	60/1	96130 TUNISIA	500/1	1000/1
96115 DENMARK	100/1	100/1	96131 PANAMA	1000/1	1000/1
96116 SWITZERLAND	80/1	100/1	96132 SAUDI ARABIA	1000/1	1000/1

Odds current as of 1/22/18

◆ Logistic Regression I

- 로지스틱 함수 β_1 해석

$$\pi(\underline{X = x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} \quad 0 \leq \pi(X = x) \leq 1$$

$$\text{Odds} = \frac{\pi(X = x)}{1 - \pi(X = x)}$$

Odds: 범주 0에 속할 확률 대비 범주 1에 속할 확률

(The ratio of the probability of belonging to class 1 to the probability of belonging to class 0)

◆ Logistic Regression I

- 로지스틱 함수 β_1 해석

$$\pi(X = x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} \quad 0 \leq \pi(X = x) \leq 1$$

$$Odds = \frac{\pi(X = x)}{1 - \pi(X = x)}$$

Odds: 범주 0에 속할 확률 대비 범주 1에 속할 확률

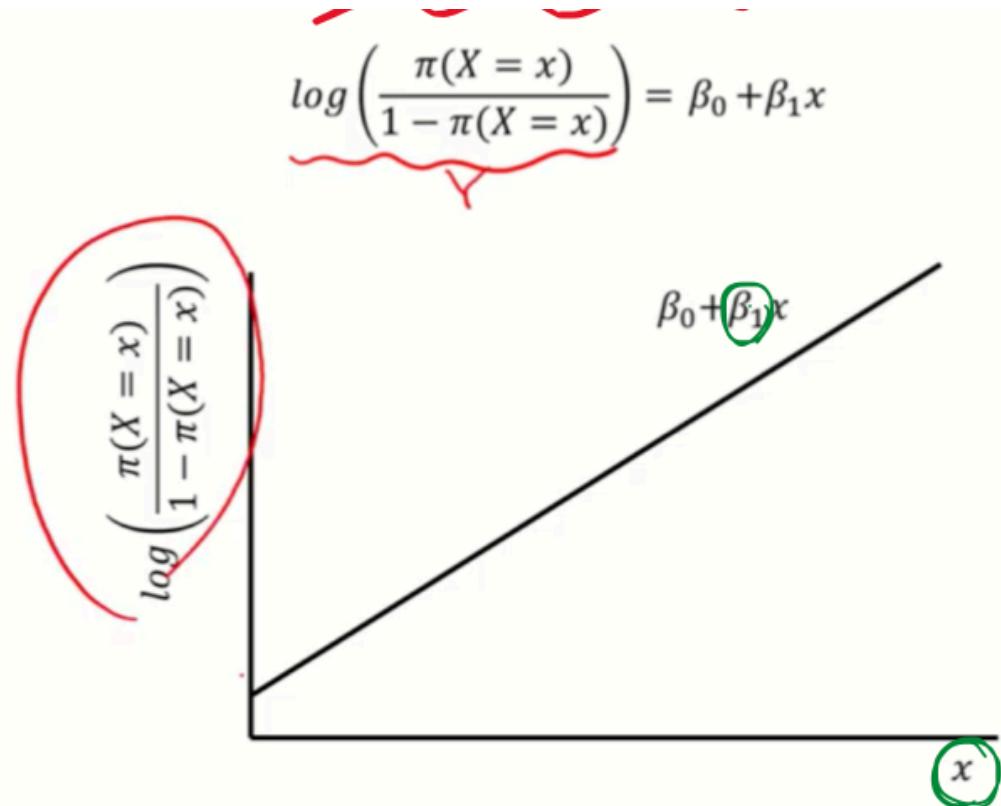
(The ratio of the probability of belonging to class 1 to the probability of belonging to class 0)

$\log(Odds) = \log\left(\frac{\pi(X = x)}{1 - \pi(X = x)}\right) = \log\left(\frac{\frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}}{1 - \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}}\right) = \beta_0 + \beta_1 x$

Logit Transform (로짓 변환)

◆ Logistic Regression I

- 로지스틱 함수 β_1 해석



↗ β_1 의 의미: x 가 한 단위 증가 했을 때 log(odds)의 증가량

Unit 02 | Logistic Regression

◆ Logistic Regression

- 회귀 계수의 해석
 - ✓ Linear Regression
 - 해당 변수가 1만큼 증가함에 따른 종속변수의 변화량

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \cdots + \hat{\beta}_d x_d$$

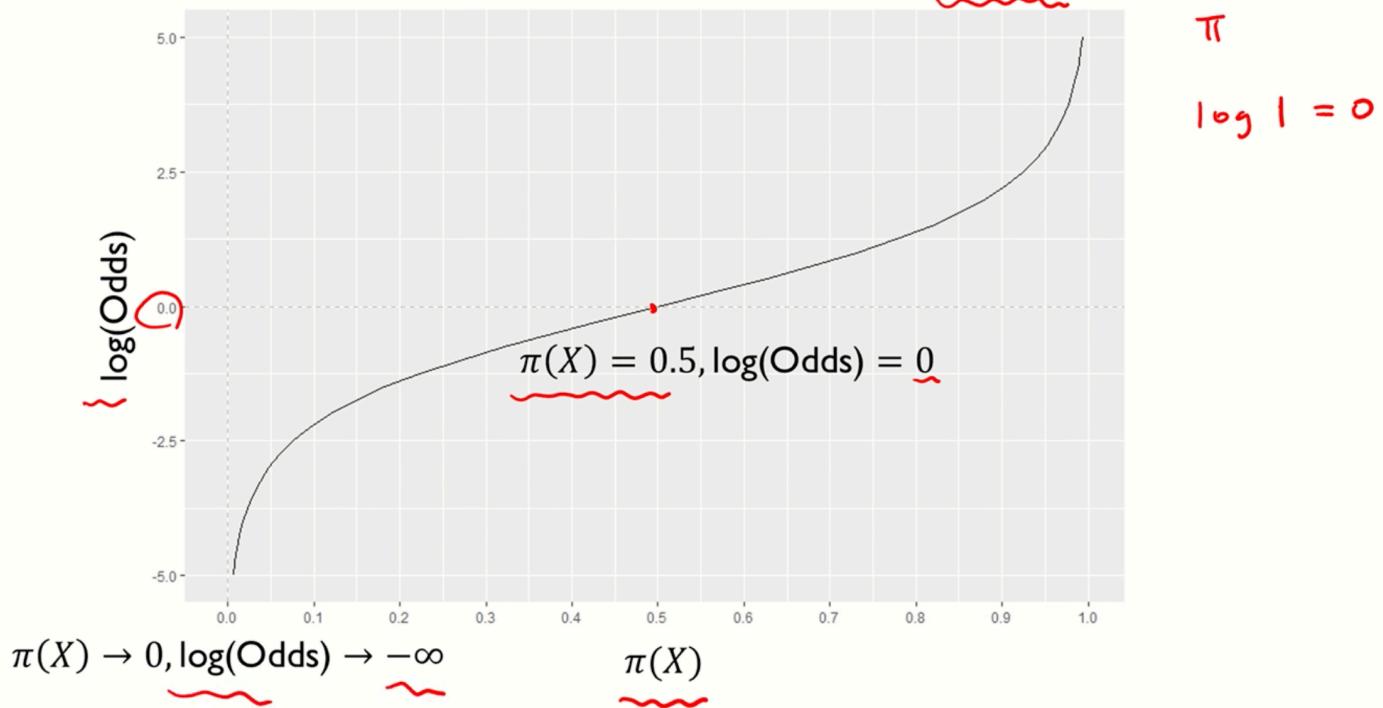
- ✓ Logistic Regression
 - 해당 변수가 1만큼 증가함에 따른 로그 오즈의 변화량

$$\log(Odds) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \cdots + \hat{\beta}_d x_d$$

◆ Logistic Regression I

- 로지스틱 함수 β_1 해석

- 성공 확률 $\pi(X)$ 에 따른 log(Odds)의 그래프



Unit 02 | Logistic Regression

◆ Logistic Regression

- Logistic Regression – 종속변수 자체가 아닌 **종속변수에 대한 Logit함수를 회귀식의 종속변수로 사용**
 - ✓ Odds의 Logit값을 종속변수로 사용한 회귀식을 추정한 뒤, 역산을 통해 구한 성공 확률 값을 기준으로 분류 값을 예측함

$$\log(Odds) = \log\left(\frac{p}{1-p}\right) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \cdots + \hat{\beta}_d x_d$$



양변 \exp 취함



$$p = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \cdots + \hat{\beta}_d x_d)}}$$

$$\frac{p}{1-p} = e^{\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \cdots + \hat{\beta}_d x_d}$$

P(성공확률)
에 대해 정리 = $\sigma(x, \beta)$

Unit 02 | Logistic Regression

◆ Logistic Regression I

- 로지스틱 회귀모델 배경
- 로지스틱 회귀모델 형태
- Odds

◆ Logistic Regression II

- 파라미터 추정
- 로지스틱 회귀모델 결과 및 해석
- 로지스틱 회귀모델 예제

◆ Logistic Regression II

- 로지스틱 함수



$$\pi(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)}}$$

$$0 \leq \pi(X) \leq 1$$

- X변수를 로지스틱 함수형태 (비선형결합)로 표현
- 관측치가 특정 범주에 속할 확률로 계산
- 확률값이 정한 기준값보다 크면 범주 1 아니면 범주 2 (이진범주 분류 문제의 경우)

◆ Logistic Regression II

- 로지스틱 함수

$$\pi(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)}} \quad \checkmark$$

$$Odds = \frac{\pi(X)}{1 - \pi(X)} = e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p}$$

- Logit Transform

$$\log(Odds) = \log \left(\frac{\pi(X)}{1 - \pi(X)} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

◆ Logistic Regression II

- 로지스틱 회귀모델 학습
- 수치최적화

- 로지스틱 회귀모델 학습: 최대 우도 추정법 (Maximum Likelihood Estimation)

$$f_i(y_i) = \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}, i = 1, 2, \dots, n$$
$$\begin{aligned} P(y_i = 1) &= \underline{\pi}_i \\ P(y_i = 0) &= \underline{1 - \pi}_i \end{aligned}$$

$$L = \prod_i f_i(y_i) = \prod_i \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$

◆ Logistic Regression II

- 로지스틱 회귀모델 학습
 - 로지스틱 회귀모델 학습: 최대 우도 추정법 (Maximum Likelihood Estimation)

$$\begin{aligned}
 f_i(y_i) &= \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}, i = 1, 2, \dots, n & P(y_i = 1) &= \pi_i \\
 && P(y_i = 0) &= 1 - \pi_i \\
 L &= \prod_i^n f_i(y_i) = \prod_i^n \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i} & \log(A \cdot B) &= \log A + \log B \\
 \ln L &= \ln \left[\prod_i^n \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i} \right] \\
 &= \ln \prod_i \left[\frac{\pi(x_i)}{1-\pi(x_i)} \right]^{y_i} + \sum_i \ln(1 - \pi(x_i)) \\
 &= \sum_i y_i \ln \left[\frac{\pi(x_i)}{1-\pi(x_i)} \right] + \sum_i \ln(1 - \pi(x_i)) \\
 &= \sum_i y_i (\underbrace{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}_{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}) + \sum_i \ln(1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p})
 \end{aligned}$$

◆ Logistic Regression II

- 로지스틱 회귀모델 학습
 - 로지스틱 회귀모델 학습: 최대 우도 추정법 (Maximum Likelihood Estimation)

✓ $\ln L = \sum_i y_i (\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p) + \sum_i \ln(1 + e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p})$

- 위 로그-우도함수 (log likelihood function)가 최대가 되는 파라미터 β 결정
- 로그-우도함수 (log likelihood function)는 파라미터 β 에 대해 비선형이므로 선형회귀 모델과 같이 명시적인 해가 존재하지 않음 (No closed-form solution exists)
- Iterative reweight least square, Conjugate gradient, Newton's method 등의 수치 최적화 알고리즘을 이용하여 해를 구함

◆ Logistic Regression II

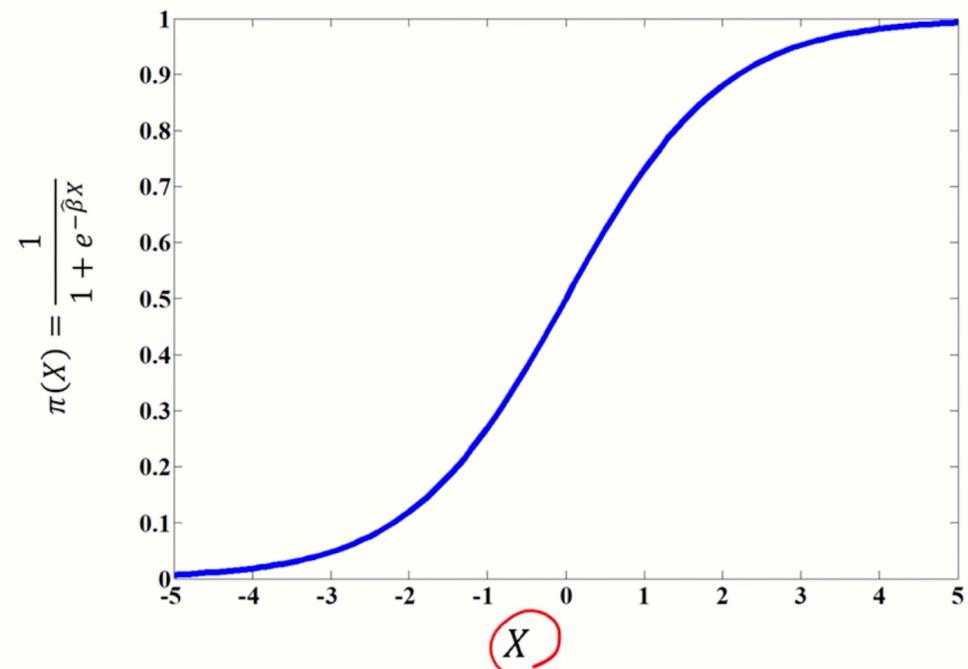
- 로지스틱 회귀모델 학습
 - Cross entropy: 두 확률분포 $(p(x), q(x))$ 의 차이
$$\text{Cross entropy} = - \sum p(x) \log q(x)$$
 - Cross entropy: 음의 log likelihood function의 기대값
 - Log likelihood function을 최대 = 입력 분포 $p(x)$ 와 파라미터가 주어졌을 때, 출력분포 $q(x)$ 의 확률을 최대
 - Cross entropy를 최소 = 입력 분포 $p(x)$ 와 출력분포 $q(x)$ 의 차이를 최소
 - Log likelihood function을 최대 = cross entropy를 최소

◆ Logistic Regression II

- 파라미터 추정 후 최종 모델

❖ 파라미터가 추정되고 난 이후 최종모델

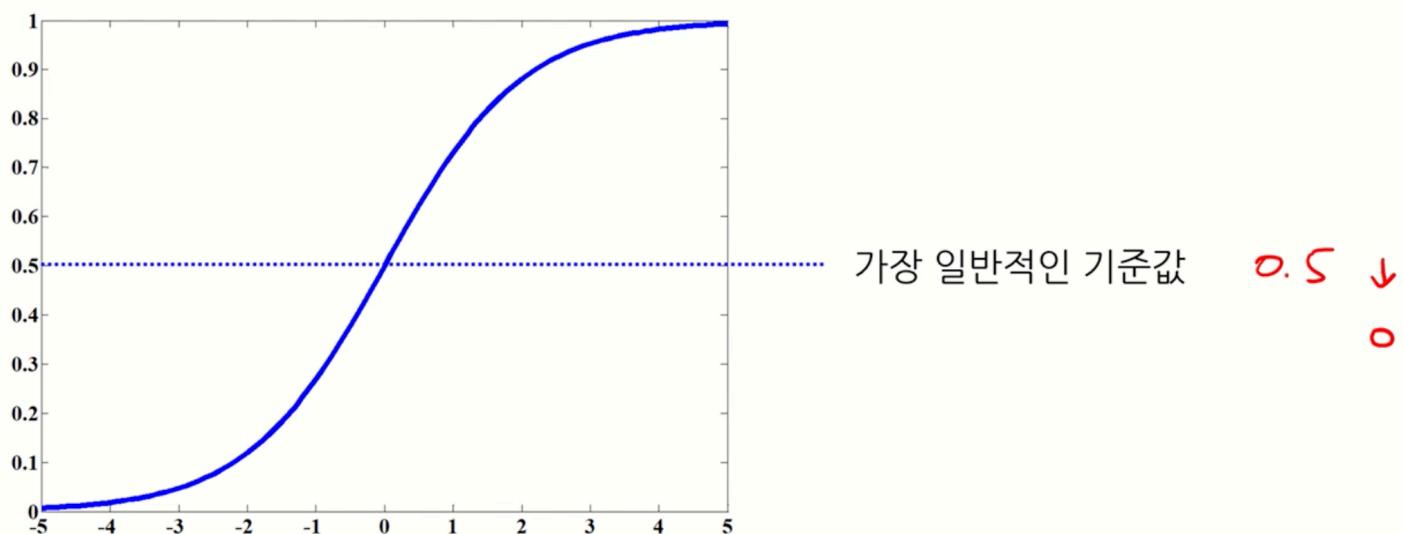
$$\pi(X) = f(X) = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_p X_p)}} = \frac{1}{1 + e^{-\hat{\beta}X}}$$



◆ Logistic Regression II

- 파라미터 추정 후 최종 모델

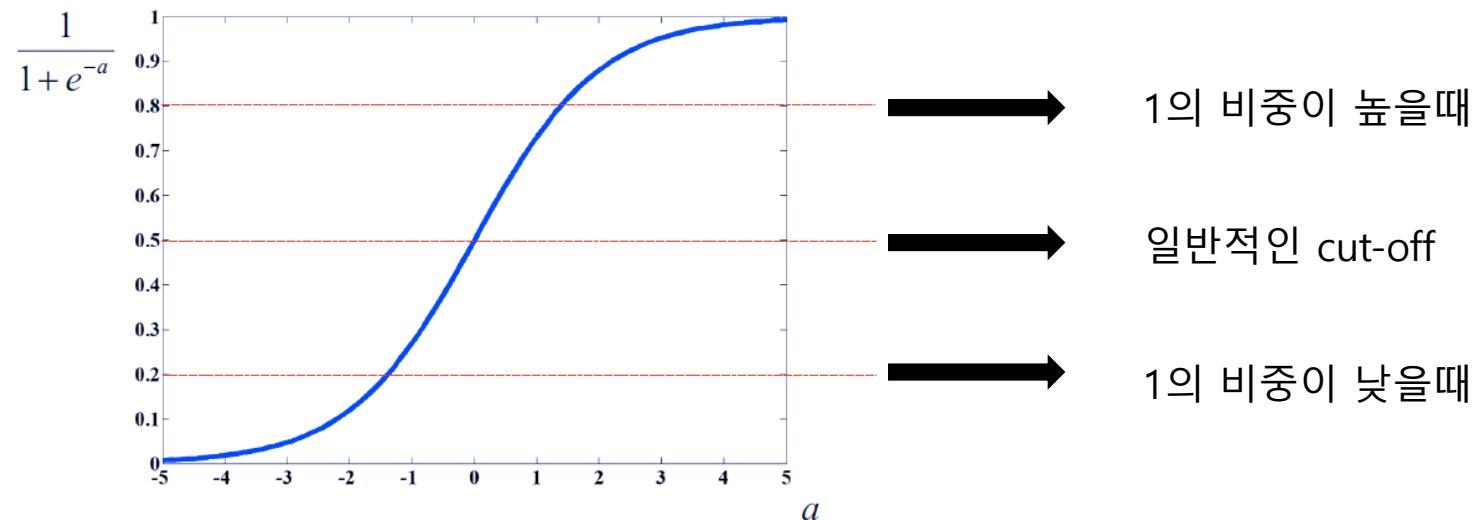
- 이진 분류를 위한 기준값(threshold) 설정
 - 일반적으로 0.5 사용



Unit 02 | Logistic Regression

◆ Logistic Regression

- Cut-off 설정
 - ✓ 회귀계수가 추정되면 설명변수가 주어졌을 때, 성공확률을 구할 수 있고, 해당 확률이 cut-off 이상이면 1, 아니면 0으로 분류할 수 있음
 - ✓ 사전확률을 고려한 cut-off 또는 검증 데이터의 성능을 최대화하는 cut-off 등을 사용함



◆ Logistic Regression II

- 승산 비율: Odds Ratio

- 승산 비율: Odds Ratio

$$\frac{\text{odds}(x_1+1, x_2, \dots, x_n)}{\text{odds}(x_1, x_2, \dots, x_n)} = \frac{e^{\widehat{\beta}_0 + \widehat{\beta}_1(X_1+1) + \dots + \widehat{\beta}_p X_p}}{e^{\widehat{\beta}_0 + \widehat{\beta}_1 X_1 + \dots + \widehat{\beta}_p X_p}} = e^{\widehat{\beta}_1}$$

- 나머지 입력변수는 모두 고정시킨 상태에서 한 변수를 1단위 증가시켰을 때 변화하는 Odds의 비율
 - x_1 이 1단위 증가하면 성공에 대한 승산 비율이 e^{β_1} 만큼 변화함
 - 회귀 계수가 양수 \rightarrow 성공확률 증가 ($\text{성공확률} \geq 1$)
 - 회귀 계수가 음수 \rightarrow 성공확률 감소 ($0 \leq \text{성공확률} < 1$)

◆ Logistic Regression II

- 로지스틱 회귀분석 결과 및 해석 (대출 여부를 예측하는 데이터)

$$f(X) = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_{12} X_{12})}}$$

↙

Input variables	Coefficient	Std. Error	p-value	Odds
Constant term	-13.20165825	2.46772742	0.00000009	*
Age	-0.04453737	0.09096102	0.62439483	0.95643985
Experience	0.05657264	0.09005365	0.5298661	1.05820346
Income	0.0657607	0.00422134	0	1.06797111
Family	0.57155931	0.10119002	0.00000002	1.77102649
CCAvg	0.18724874	0.06153848	0.00234395	1.20592725
Mortgage	0.00175308	0.00080375	0.02917421	1.00175464
Securities Account	-0.85484785	0.41863668	0.04115349	0.42534789
CD Account	3.46900773	0.44893095	0	32.10486984
Online	-0.84355801	0.22832377	0.00022026	0.43017724
CreditCard	-0.96406376	0.28254223	0.00064463	0.38134006
EducGrad	4.58909273	0.38708162	0	98.40509796
EducProf	4.52272701	0.38425466	0	92.08635712

Unit 02 | Logistic Regression

◆ Logistic Regression

- Performance evaluation index

Confusion Matrix		Predict	
		Positive	Negative
Actual	Positive	a	b
	Negative	c	d

- ✓ Recall(재현율) = $\frac{a}{a+b}$
- ✓ Precision(정밀도) = $\frac{a}{a+c}$
- ✓ F1-measure = $\frac{2*recall*precision}{recall+Precision}$

- ✓ BCR(균형정확도) = $\sqrt{\frac{a}{a+b} * \frac{d}{c+d}}$
- ✓ ACC(정분류율) = $\frac{a+d}{a+b+c+d}$

Unit 02 | Logistic Regression

◆ Logistic Regression

- Performance evaluation index

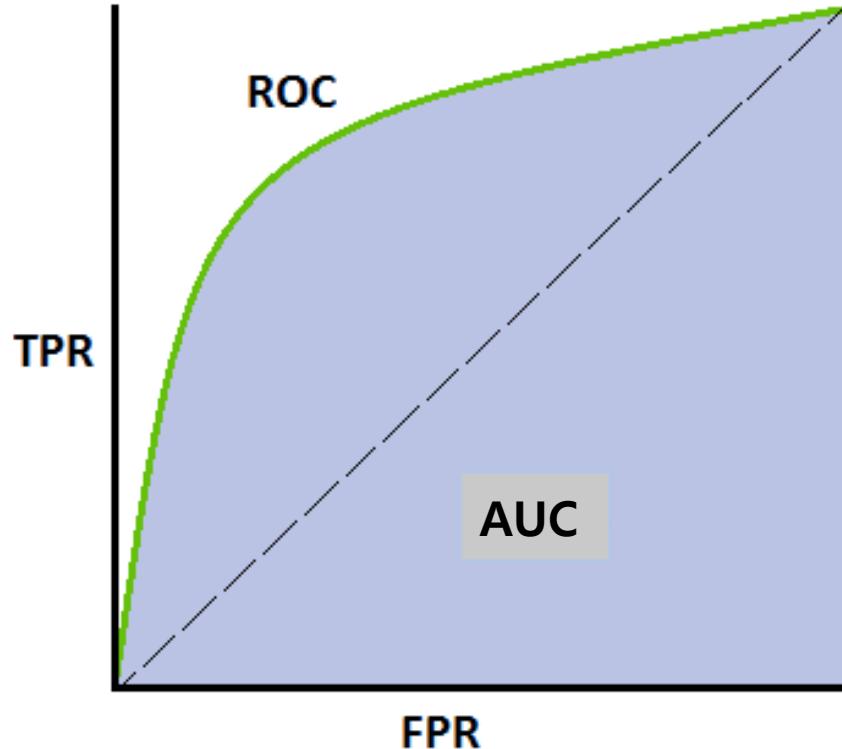
Confusion Matrix		Predict	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

- ✓ $Specificity = \frac{TN}{TN+FP} = \frac{d}{c+d}$ = Negative로 판단한 것 중 실제 Negative 비율
- ✓ $Sensitive (Recall) = \frac{TP}{TP+FP} = \frac{a}{a+b}$ = 원래 Positive 중에서 Positive로 예측한 비율
= True Positive Rate
- ✓ $1 - Specificity = False Positive Rate$

Unit 02 | Logistic Regression

◆ Logistic Regression

- ROC Curve
 - ✓ TPR과 FPR은 서로 반비례적인 관계에 있으므로 둘다, 어떤 기준(언제 1이라고 예측 할 지)을 연속적으로 바꾸면서 측정 해야한다.
 - ✓ 그러면 결국 TPR과 FPR의 여러가지 상황을 고려해서 성능을 판단해야 하는데, 이것을 한눈에 볼 수 있게 한 것이 바로 ROC 커브이다.
 - ✓ AUC : ROC Curve의 밑면적 값, 높을수록 좋다



Unit 02 | Logistic Regression

◆ Logistic Regression II

- 파라미터 추정
- 로지스틱 회귀모델 결과 및 해석
- 로지스틱 회귀모델 예제

◆ Logistic Regression II

- 선형 회귀처럼 단순하게 미분을 통해 파라미터를 추정할 수 없었다
- **수치 최적화**를 이용해서 파라미터를 추정했다.
- Log likelihood, Cross entropy ...

Unit 01 | Machine Learning

Unit 02 | Logistic Regression I, II

Unit 03 | MLE(Maximum Likelihood Estimation)

Unit 04 | Optimizer

Unit 05 | Tutorial & Assignment

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

- Maximum Likelihood Estimation

- ✓ 최대우도추정(maximum likelihood estimation)이란 모수(parameter)가 미지의 θ 인 확률분포에서 뽑은 표본(관측치)들을 바탕으로 확률분포의 모수인 θ 를 추정하는 기법
- ✓ 여기에서 우도(likelihood)란 이미 주어진 표본들에 비추어 봤을 때 모집단의 모수 θ 에 대한 추정이 그럴듯한 정도를 가리킴
- ✓ 따라서, Likelihood $L(\theta|x)$ 는 θ 가 전제되었을 때 표본 x 가 등장할 확률인 $p(x|\theta)$ 에 비례함

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

- Maximum Likelihood Estimation

- ✓ 최대우도추정(maximum likelihood estimation)이란 모수(parameter)가 미지의 θ 인 확률분포에서 뽑은 표본(관측치)들을 바탕으로 확률분포의 모수인 θ 를 추정하는 기법

무슨 말인지 이해가 잘 가지 않는다.

- ✓ 여기에서 우도(likelihood)란 이미 주어진 표본들에 비추어 봤을 때 모집단의 모수 θ 에 대한 추정이 그럴듯한가를 의미함
- ✓ 따라서, Likelihood $L(\theta|x)$ 는 θ 가 전제되었을 때 표본 x 가 등장할 확률인 $p(x|\theta)$ 에 비례함

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

- Maximum Likelihood Estimation

- ✓ 우리는 절대로 모수를 알 수 없다. 따라서 표본(sample)을 통해서 모집단의 특성인 모수를 파악해야한다.
- ✓ 이 때, 우리가 **가정**하는 것은 각각의 표본을 추출할 때의 확률밀도함수 혹은 확률질량함수의 양상을 알고 있다는 것이다. (즉, 수학적으로 각 sample을 뽑을 확률밀도함수에 대해서 어떤 양상을 따를지 알고 있을 때 모수를 추정하고자 한다면 최대우도법을 쓸 수 있다.)

Q. Bernoulli Random Variable?

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

• Maximum Likelihood Estimation

- ✓ 어떤 모수 θ 로 결정되는 확률변수들의 모임 $D_\theta = (X_1, X_2, \dots, X_n)$ 이 있고 D_θ 의 확률밀도함수나 확률질량함수가 $f(x)$ 이고, 그 확률변수들에서 각각 값 X_1, X_2, \dots, X_n 을 얻었을 경우 Likelihood $L(\theta)$ 는 다음과 같다.

$$L(\theta) = f_\theta(x_1, x_2, \dots, x_n)$$

Q 확률 변수에서 각각 값
 $p(X=x_1), p(X=x_2), \dots$ 를 얻는
게 아닌가요?

- ✓ 여기에서 Likelihood를 최대로 만드는 θ 는

$$\hat{\theta} = \operatorname{argmax}_\theta L(\theta) \text{ 가 된다.}$$

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

• Maximum Likelihood Estimation

- ✓ 이 때 X_1, X_2, \dots, X_n 이 모두 독립적이고 같은 확률분포를 가지고 있다면 L 은 다음과 같이 표현이 가능하다

$$L(\theta) = \prod_i^n f_{\theta}(x_i)$$

- ✓ 또한, 로그함수는 단조 증가하므로, L 에 로그를 써운 값의 최댓값은 원래 값 $\hat{\theta}$ 와 같고, 이 경우 계산이 비교적 간단해진다.

$$L^*(\theta) = \log(L(\theta)) = \sum_i^n \log f_{\theta}(x_i)$$

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

- Maximum Likelihood Estimation
 - ✓ 예를 들어 투빅스 11기 12기 중에서 한명을 표본으로 추출하는데 추출된 사람이 남자인지 여자인지를 알려고 한다고 하면, 이 때 표본 확률변수가 갖는 확률분포는 베르누이 분포

$$f(X) = p^X(1-p)^{1-X}$$

- ✓ 그러면 총 n명에 대해 추출했을 때의 likelihood는 다음과 같이 정해진다.

$$L(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \quad (a)$$

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

• Maximum Likelihood Estimation

- ✓ 가령 10명의 사람을 추출했는데 1번부터 10번 사람까지의 성별이 각각 {남, 여, 남, 남, 여, 여, 남, 남, 여, 남} 이라고 해보자.
- ✓ 남자라면 $X_i = 0$ 이라고 하고 여자라면 $X_i = 1$ 이라고 결정한다고 했을 때, 현 상태에서 $x_i (i = 1, 2, \dots, 10)$ 은 {0, 1, 0, 0, 1, 1, 0, 0, 1, 0} 이라고 할 수 있다.

그러면 식 (a)는 다음과 같을 것이다.

$$L(X_1 = 0, X_2 = 1, \dots, X_{10} = 0 | p) = \prod_{i=1}^{10} p^{x_i} (1 - p)^{1-x_i} \dots$$

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

- Maximum Likelihood Estimation

- ✓ 그렇다고 해서 우리가 p (표본이 여성일 확률)를 알수 있느냐면 그렇진 못하다. 즉, 우리가 정작 알아야 하는 것은 이 p 를 어떻게 결정할 것인가이다.
- ✓ 이 p 를 잘 결정하려면 최대한 모집단의 p 와 비슷할수록 잘 결정한 것이라고 할 수 있다. 최대우도법에서의 기본 가정은 지금 이러한 상황은 랜덤하게 부여된 것인데,
- ✓ 이 상황이 나온 것은 이렇게 나올 가능성이 가장 높았기 때문일 것이라는 것이다.
- ✓ 따라서, '이 상황'을 설명하는 확률 f 를 최대화 할 수 있는 모수 p 를 찾는 것이 최대우도법이 시행하고자 하는 바이다.

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

• Maximum Likelihood Estimation

- ✓ 예시에서 제기된 문제를 계속 풀어보도록 하자. 그런데, 식 (a)에서 함수 f 를 p 에 대해 편미분 하려면 쉽지 않다.
- ✓ 우리는 여기서 로그 함수의 단조증가 성질을 활용하여 $L^* = \log(L)$ 라는 보조 방정식을 도입하도록 하자.

그러면 L^* 은 다음과 같다.

$$L^* = \log(L) = \sum_{i=1}^n \log(p^{x_i}(1-p)^{1-x_i}) = \sum_{i=1}^n \{x_i \log(p) + (1-x_i) \log(1-p)\}$$

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

• Maximum Likelihood Estimation

- ✓ 이제 보조방정식 L^* 을 p 에 대해 편미분 하는 것이 쉬워진다.
- ✓ 그런 다음 L^* 의 p 에 대한 편미분이 0이 되는 p 를 찾으면 최대우도를 만족하는 모수 p 를 추정 할 수 있다.

$$\begin{aligned} L^* &= \frac{\sum_{i=1}^n x_i}{p} - \frac{\sum_{i=1}^n (1-x_i)}{1-p} \\ &= \frac{n\bar{X}}{p} - \frac{n(1-\bar{X})}{1-p} = 0 \end{aligned}$$

따라서

$$\begin{aligned} \Rightarrow \frac{n\bar{X}}{p} &= \frac{n(1-\bar{X})}{1-p} \\ \Rightarrow (1-p)\bar{X} &= (1-\bar{X})p \\ \Rightarrow \bar{X} - p\bar{X} &= p - \bar{X}p \\ \therefore p &= \bar{X} \end{aligned}$$

Unit 03 | MLE(Maximum Likelihood Estimation)

◆ Logistic Regression

- Maximum Likelihood Estimation

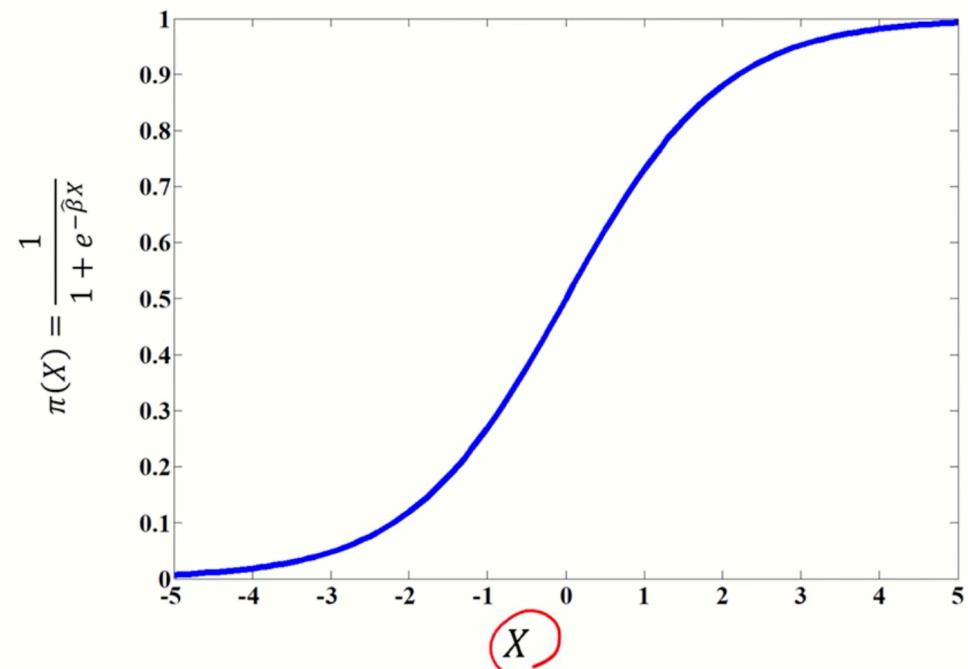
- ✓ 따라서, $p = \bar{X}$ 로 모수 p 를 추정하는 것이 적절하다는 것을 알 수 있다.
- ✓ 생각해보면 자연스러운 것이 모비율 추정 시 현재 모여있는 사람의 성비를 가지고 모비율을 추정할 수 밖에 없고, 아마 그런 모비율이 있었기 때문에 현재 상태가 만들어 진 것은 아닐까? 라고 추정하는 것은 자연스럽다.

◆ Logistic Regression II

- 파라미터 추정 후 최종 모델

❖ 파라미터가 추정되고 난 이후 최종모델

$$\pi(X) = f(X) = \frac{1}{1 + e^{-(\hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_p X_p)}} = \frac{1}{1 + e^{-\hat{\beta}X}}$$



Content

Unit 01 | Machine Learning

Unit 02 | Logistic Regression

Unit 03 | MLE(Maximum Likelihood Estimation)

Unit 04 | Optimizer

Unit 05 | Tutorial & Assignment

Unit 04 | Optimizer

◆ Optimizer

- Optimizer
 - ✓ Machine learning 문제를 풀다보면 Objective function을 만들고 그 **objective function**을 **optimize** 해야하는 경우가 매우 빈번하게 발생함.
 - ✓ 간단히 생각해서 **loss function**을 **minimize**하는 것도 **optimization**이다. 그렇다면 그런 optimization은 도대체 어떻게 해야하는 것일까.
 - ✓ 여러가지 방법이 있지만, 이번 시간에서는 간단한 optimization이라는 것에 대한 컨셉을 다루고, 그 중 특수 케이스인 convex optimization에 대해 다룸

Unit 04 | Optimizer

◆ Optimizer

- Optimizer
 - ✓ 대부분의 Optimization은 아래와 같은 식으로 표현할 수 있을 것이다.

$$\min f(x) \text{ s.t. } g(x) = c$$

- ✓ 여기에서 $f(x)$, $g(x)$ 는 함수이다. 어떤 함수의 optimum point, 즉 그것이 최소이거나 혹은 최대인 지점을 찾는 과정을 optimization이라고 한다고 생각하면 간단
- ✓ 엄청 간단하게 생각해보면 $f(x)$ 는 loss function이고, $g(x)$ 는 일종의 제약조건으로 생각하면 됨

Unit 04 | Optimizer

◆ Optimizer

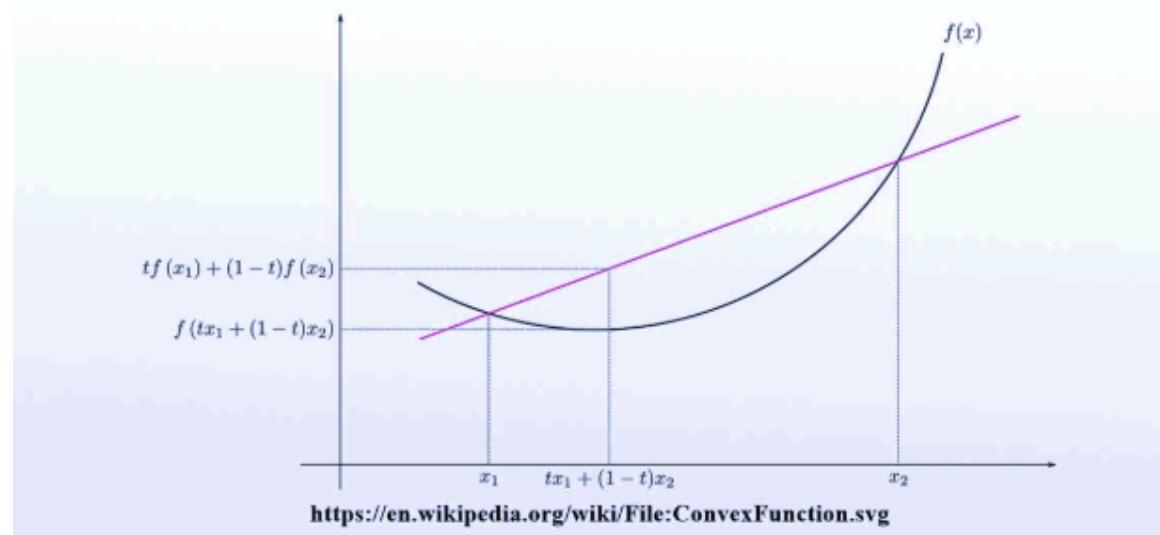
- Optimizer
 - ✓ Machine learning 문제를 풀다보면 이렇게 optimization을 해야하는 일이 아주 빈번하게 발생하는데, 안타깝게도 항상 이런 function들의 optimum point를 찾을 수 있는 것은 아님
 - ✓ 가장 간단하게 생각했을 때 이런 point를 찾는 방법은 미분을 하고 그 값이 0이 되는 지점을 찾는 것인데, 안타깝게도 미분 자체가 되지 않는 함수가 존재할 수도 있다
 - ✓ 또한 미분값이 0이라고 해서 반드시 극점인 것은 아니기 때문이다. (saddle point를 생각해보자.)

Unit 04 | Optimizer

◆ Optimizer

- Optimizer
 - ✓ 따라서 대부분의 경우에 이런 방법으로 극점을 구하는 것은 불가능하며, 매우매우 특수한 일부 경우에 대해서 완전한 optimum을 찾는 것이 알려져 있다. 그리고 그 경우가 바로 convex optimization이다.

Convex function

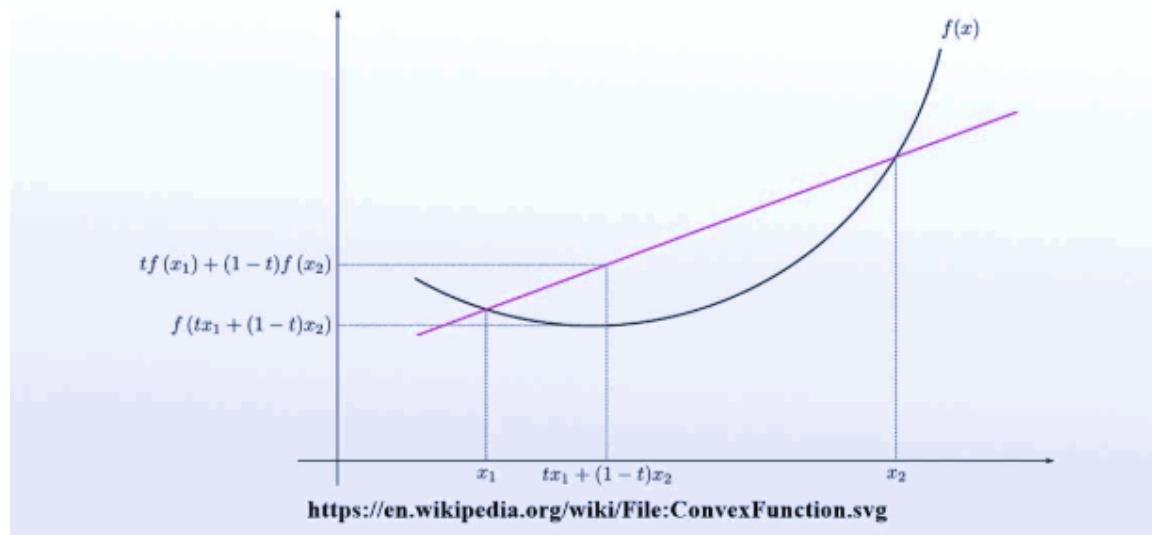


Unit 04 | Optimizer

◆ Optimizer

- Optimizer

Convex function



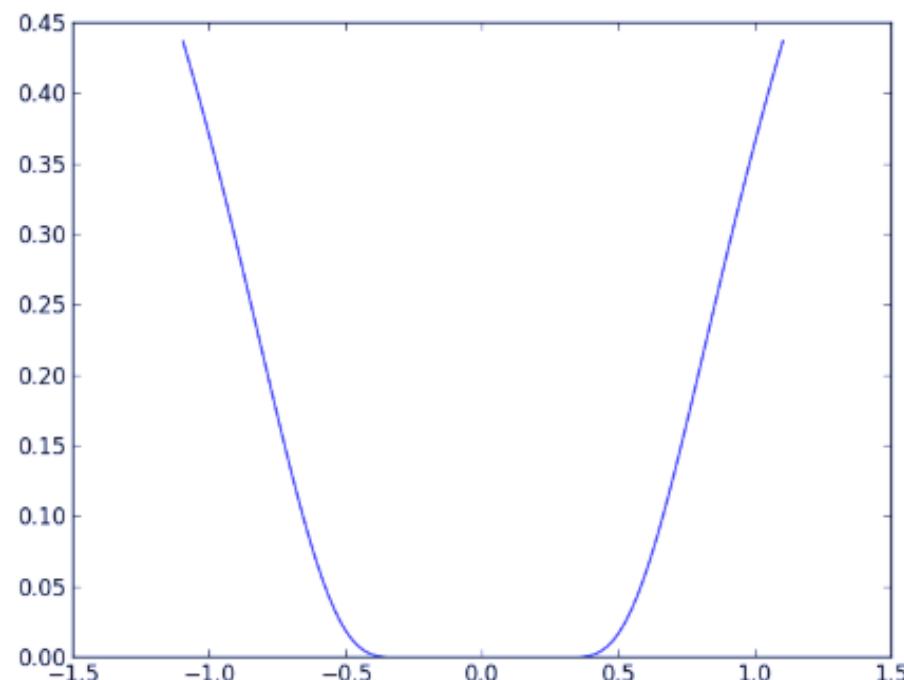
$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2) \text{ for } \forall x_1, x_2 \in X, \forall \lambda \in [0, 1]$$

Unit 04 | Optimizer

◆ Optimizer

- Optimizer

- ✓ Convex function이 좋은 이유는 반드시 optimal value가 하나 밖에 존재하지 않는다는 것이다.
여기에서 optimal point가 하나라고 얘기하지 않은 이유는 아래와 같은 예가 있기 때문이다.



Unit 04 | Optimizer

◆ Optimizer

- Optimizer
 - ✓ 이 함수는 optimal value는 unique하게 존재하지만, 그 값을 가지는 point가 unique하지는 않다.
 - ✓ 따라서 unique한 optimal point를 찾기 위해서는 하나의 조건이 더 필요한데, 바로 strictly convex라는 조건이다.

$$f(\lambda x_1 + (1 - \lambda)x_2) < \lambda f(x_1) + (1 - \lambda)f(x_2) \text{ for } \forall x_1, x_2 \in X, \forall \lambda \in [0, 1]$$

- ✓ 이 조건은 위의 식에서 = 이 빠진 형태이다. 즉 \leq 가 $<$ 으로 바뀌는 것이다.
- ✓ 이런 strictly convex function에 대해서 optimal point가 unique하게 존재한다는 것을 증명할 수 있으며, 증명과정은 크게 어렵지 않으니 [링크](#) 등을 참고하면 될 것 같다.
- ✓ 아무튼 strictly convex function은 minimum point가 unique하게 존재하기 때문에, 이런 convex function에 대해서 우리는 어떤 optimization algorithm을 design할 수 있다.

Unit 04 | Optimizer

◆ Optimizer

- Optimizer
 - ✓ 이런 convex optimization의 subset으로 linear programming, quadratic programming, semidefinite programming 등이 존재한다.
 - ✓ 여기서는 그런 특수한 경우는 다루지 않고, 일반적인 convex optimization에서 사용할 수 있는 알고리즘들을 다룸.
 - ✓ Gradient descent method, Newton method and Lagrange multiplier 등이 있다.

Unit 04 | Optimizer

◆ Optimizer

- Gradient Descent Algorithm
 - ✓ 최적해에 가까워지는 방향으로 조금씩 움직이면서 최적의 해를 찾는 최적화 알고리즘
 - ✓ 산 정상 위에 우리가 서 있다고 가정
 - ✓ 우리가 알 수 있는 정보는 내 위치와 내 주변 위치들의 높이 차이밖에 없다고 가정
 - ✓ 만약 내가 산의 가장 낮은 위치로 내려가야하는 상황이라면 어떻게 내려가면 낮은 위치에 도달할 수 있을까?
 - ✓ 가장 간단한 방법은 가장 기울기가 가파른 방향을 골라서 내려가는 것
 - ✓ 그러다보면 언젠가는 기울기가 0이 되는 지점에 도달하게 될 것이고, 그 지점이 주변에서는 가장 낮은 지점이 될 것이다.

Unit 04 | Optimizer

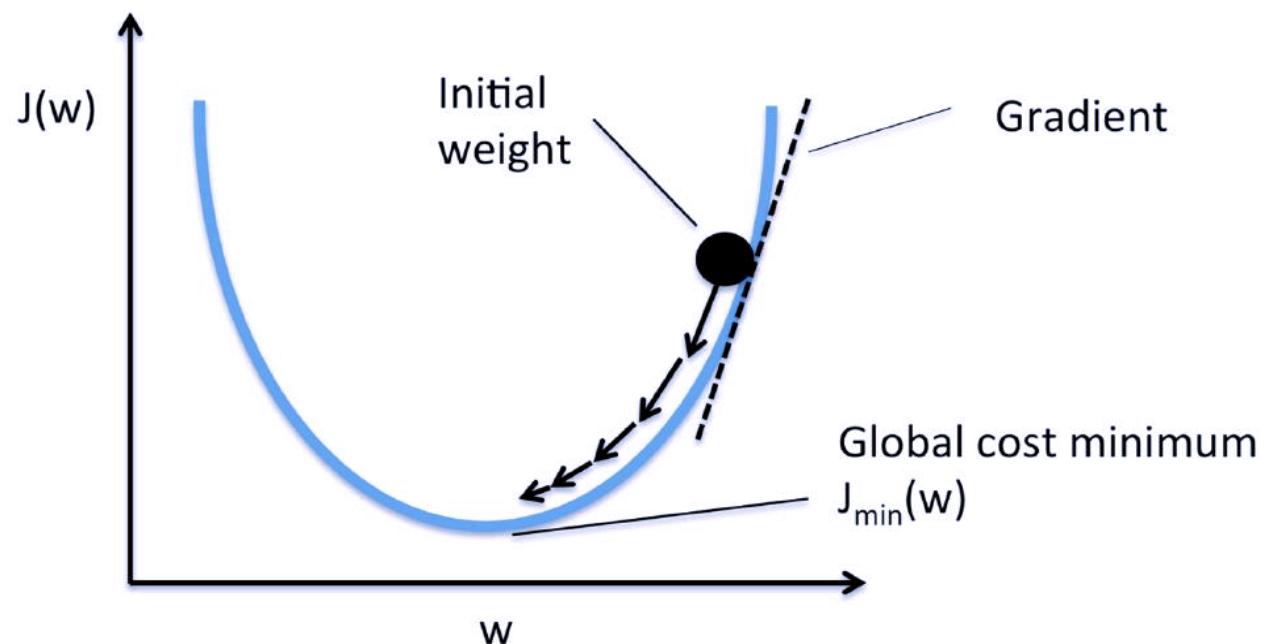
◆ Optimizer

- Gradient Descent Algorithm
 - ✓ 그러다보면 언젠가는 기울기가 0이 되는 지점에 도달하게 될 것이고, 그 지점이 주변에서는 가장 낮은 지점이 될 것이다.
 - ✓ 만약 산의 높이가 convex function이라면, 즉 가장 낮은 지점이 unique하다면, 그렇게 도달한 지점이 우리가 원했던 가장 optimal한 지점이라는 것을 알 수 있다.

Unit 04 | Optimizer

◆ Optimizer

- Gradient Descent Algorithm
 - ✓ 파란선 : 가중치에 대한 Loss function
 - ✓ 검은점 : 현재 해의 위치
 - ✓ 화살표 : Loss function을 최적화하기 위해 가중치가 이동해야 하는 방향



Unit 04 | Optimizer

◆ Optimizer

- Gradient Descent Algorithm – [링크](#)

$$w \leftarrow w - \alpha \frac{\partial}{\partial w} J(w)$$

✓ $\frac{\partial}{\partial w} J(w)$: gradient

- 가중치에 대한 목적함수의 미분값
- 미분 값의 부호는 최적해로 가기 위한 방향과 반대 값을 가짐

✓ α : Learning Rate

- 움직이는 정도를 조정하는 계수로 클수록 빠르게 학습하지만 최적해로 수렴하지 못할 수도 있음

Content

Unit 01 | Machine Learning

Unit 02 | Logistic Regression

Unit 03 | MLE(Maximum Likelihood Estimation)

Unit 04 | Optimizer

Unit 05 | Tutorial & Assignment

Unit 05 | Tutorial & Assignment

◆ Assignment1

- 실습코드 1에서 Q1, Q2 채우기

◆ Assignment2

<Money Ball> <https://www.kaggle.com/wduckett/moneyball-mlb-stats-19622012>

1. 어떤 지표가 우리 팀을 Play-off로 이끄는지 학습해보기
 - 3-1. Moneyball Kernel - Using data from The History...
 - 3-2. EDA & Preprocessing
 - 3-3. Logistic Regression

Unit 05 | Tutorial & Assignment

◆ Tutorial

- Logistic Regression 맛보기 with Python(Logistic_Regression_01.ipynb)

◆ Assignment3

1. 튜토리얼 파일(Logistic_Regression_01.ipynb)을 수정하세요.

- * confusion matrix와 ROC curve를 활용하여 cut-off만 조정
- * 새로운 결과값 도출 및 의미해석

2. MLE를 Gradient Descent의 Loss function으로 사용하여 최적화하기

- * Logistic Regression의 회귀계수를 추정하는 MLE와 Optimizer 중에 하나인 GD를 배웠습니다.
- * MLE를 최적화 해보세요.(MLE에 마이너스를 곱하면 Convex 함수가 됩니다)

References

◆ Reference

- 투빅스 7기 최희정님 자료, 투빅스 7기 전종섭님 자료
- 투빅스 10기 박성진님 자료
- 모두의 딥러닝 머신러닝, 로지스틱회귀
- 고려대학교 김성범 교수님의 머신러닝 로지스틱 회귀 강의 1,2
- [Ratsgo's blog](#)
- [조대협님 blog](#)
- [Quora](#)
- [공돌이의 수학정리노트](#)
- [Lee, I. Optimization. Retrieved from http://issactoast.com](#)
- [SanghyukChun's Blog – Convex Optimization](#)
- [Kaggle – 타이타닉](#)

<이미지>

<http://blog.bidmotion.com/2016/06/23/good-morning-have-you-used-machine-learning/arthur-samuel-quote-machine-learning/>

Q & A

